

Comprensión de los Datos y Descripción de Variables



Etapa 2

subtitulo

ANGEL RUBEN GALINDO ALVAREZ · A00228356

MA2003B Análisis Multivariado | Blanca Rosa Ruiz Hernández
Raúl Gómez Muñoz

Table of contents

Objetivo del Análisis y Justificación del Alcance	2
Técnicas Estadísticas	2
Diccionario de Variables	3
Características Estadísticas	4
Exploración Visual de los Datos	5
Verificación de la Calidad de los Datos	5
5. Resumen, Próximos Pasos y Preguntas Emergentes	6
6. Anexos y Repositorio	6
Declaratoria de uso de IA durante el desarrollo del trabajo	6

Objetivo del Análisis y Justificación del Alcance

Pregunta de Investigación: ¿Cómo interactúan las variables meteorológicas para influir simultáneamente en las concentraciones atípicas de los principales contaminantes criterio (PM_{10} , $PM_{2.5}$ y O_3) a través de las diferentes estaciones de monitoreo del Área Metropolitana de Monterrey durante el periodo 2020-2025?

Objetivo General: Desarrollar y validar modelos estadísticos multivariados y de aprendizaje automático que predigan la concentración conjunta de PM_{10} , $PM_{2.5}$ y O_3 mediante el registro histórico 2020-2025. Esto permitirá identificar los detonantes meteorológicos por zona y dotar al SIMA de una herramienta predictiva integral para contingencias.

Se mantuvo el análisis conjunto porque las partículas suspendidas (PM_{10} y $PM_{2.5}$) comparten fuentes de emisión y alta colinealidad, mientras que el ozono (O_3) sigue un ciclo fotoquímico radicalmente distinto impulsado por calor y radiación. Integrar esta dualidad climática en un solo sistema aporta un valor superior para la política pública frente a modelos aislados.

Técnicas Estadísticas

Para dar respuesta al objetivo multi-contaminante y mantener una interpretabilidad total que permita al SIMA traducir los resultados en políticas públicas, se implementarán las siguientes técnicas estadísticas:

- **Estadística Descriptiva y Detección de Valores Atípicos:** Uso de diagramas de caja para perfilear las concentraciones base y aislar estadísticamente los eventos de contingencia ambiental segmentados por estación.
- **Análisis de Correlación Multivariada:** Fundamental para entender la sinergia directa entre contaminantes (ej. correlación positiva PM_{10} - $PM_{2.5}$) y su antagonismo con el clima, manteniendo las variables en sus escalas físicas originales.
- **Factor de Inflación de la Varianza (VIF):** Técnica diagnóstica interpretable para detectar y eliminar la multicolinealidad entre variables meteorológicas, garantizando que los modelos posteriores sean estables sin recurrir a la creación de componentes artificiales inescrutables.
- **Árboles de Decisión (Random Forest):** Algoritmos de aprendizaje automático explicables que estructuran el pronóstico mediante divisiones lógicas legibles por humanos. Se priorizarán modelos con profundidad controlada para evitar opacidad y asegurar la interpretabilidad de las reglas.

Para lograr la predicción de la contaminación, el dataset imputado (SIMA_Diario_Imputado.csv) consolida lecturas diarias.

El archivo SIMA_Diario_Imputado.csv es el resultado de consolidar seis archivos de Excel con registros horarios históricos (2020-2025) provenientes de las 15 estaciones de monitoreo del Área Metropolitana de Monterrey. Para transformar esta información bruta en un dataset manejable, los datos se agruparon de manera diaria aplicando un umbral: solo se calcularon y validaron los promedios para aquellos días que contaban con al menos 18 horas de medición efectiva. Finalmente,

los vacíos de información generados por fallas en los sensores o días incompletos se trataron mediante técnicas de imputación secuencial respetuosas con el orden cronológico, garantizando una base de datos continua y libre de data leakage para la etapa de modelado predictivo.

Importancia de la Estación de Monitoreo: La variable Estacion es categórica y resulta un eje crítico del modelo. La orografía de la Zona Metropolitana de Monterrey (rodeada de montañas) provoca microclimas y “trampas” de aire; por lo tanto, el comportamiento del PM_{10} en la estación suroeste es estadísticamente distinto al de la estación sur. Ignorar esta variable mezclaría los patrones de dispersión.

Diccionario de Variables

Variable	Descripción	Tipo de Dato	Rango / Valores Posibles	Valores Nulos
Fecha	Fecha cronológica de la lectura	Cualitativa (Ordinal)	2020-01-01 a 2025-12-31	0
Estacion	Código de la estación de monitoreo	Cualitativa (Nominal)	15 valores (ej. CE, NE, SO, SUR)	0
PM10	Partículas menores a 10 micrómetros (Objetivo)	Cuantitativa (Continua)	0– > 500 $\mu\text{g}/\text{m}^3$	0
PM2.5	Partículas menores a 2.5 micrómetros	Cuantitativa (Continua)	0– > 300 $\mu\text{g}/\text{m}^3$	0
TOUT	Temperatura ambiente externa	Cuantitativa (Continua)	–5.0 a 45.0 °C	0
RH	Humedad relativa	Cuantitativa (Continua)	0 a 100 %	0
WSR	Velocidad del viento	Cuantitativa (Continua)	0 a 50 km/h	0
PRS	Presión atmosférica	Cuantitativa (Continua)	600 a 800 mmHg	0
O3	Ozono	Cuantitativa (Continua)	0 a 200 ppb	0
NO2	Dióxido de nitrógeno	Cuantitativa (Continua)	0 a 100 ppb	0
CO	Monóxido de carbono	Cuantitativa (Continua)	0 a 10 ppm	0

Características Estadísticas

Dimensión del dataset: 31449 registros y 18 columnas.

Estadísticas de Variables Cuantitativas:


	mean	mediana	moda	std	varianza	rango	min	max
Horas_Registradas	23.99	24.00	24.00	0.08	0.01	2.00	22.00	24.00
CO	1.32	1.15	1.99	0.85	0.73	9.16	0.05	9.21
NO	15.32	7.10	7.10	29.27	856.96	426.79	0.50	427.29
NO2	14.68	12.72	12.52	8.88	78.89	95.12	0.06	95.18
NOX	29.45	20.28	17.28	32.50	1056.52	457.45	0.50	457.95
O3	26.78	26.50	26.88	9.42	88.80	76.25	1.50	77.75
PM10	57.46	52.29	42.00	27.85	775.62	295.78	5.76	301.54
PM2.5	20.27	18.97	19.78	10.18	103.54	189.39	2.00	191.39
PRS	715.24	714.26	726.25	9.27	85.84	65.86	681.81	747.67
RH	54.14	57.13	61.71	24.19	584.92	565.46	-465.74	99.72
SO2	4.96	4.15	15.95	3.13	9.81	61.19	0.59	61.78
SR	-0.00	0.15	0.00	24.63	606.56	4372.67	-4347.32	25.34
TOUT	22.79	24.51	24.12	8.01	64.23	94.58	-57.79	36.78
WDR	140.96	134.21	2.15	62.18	3866.97	575.02	-217.88	357.14
WSR	8.30	7.90	7.73	5.33	28.43	585.55	-426.69	158.86
RAINF	0.39	0.00	0.00	64.88	4208.96	14896.00	-9998.90	4897.10

Tabla de Frecuencia (Variable Cualitativa - Estación):

	Estacion	Frecuencia
0	CE	2192
1	NE	2192
2	NE2	2192
3	NO	2192
4	NO2	2192
5	NTE2	2192
6	NTE	2192
7	SE3	2192
8	SO	2192
9	SE	2192
10	SE2	2192
11	SO2	2192
12	SUR	2192
13	NE3	1826
14	NO3	1127

Exploración Visual de los Datos

A continuación, visualizamos el comportamiento de las variables cuantitativas (distribución, asimetría, dispersión espacial y correlación multivariada) y cualitativas, utilizando la base de datos validada.



Verificación de la Calidad de los Datos

- **Valores Nulos:** 0 detectados.
- **Registros Duplicados:** 0 detectados.
- **Valores Negativos Inconsistentes:** 85 detectados.
- **Acción:** Los valores negativos han sido corregidos truncándolos a 0 (límite físico posible).
- **Formato de Fechas Correcto:** Sí

Conclusión de Calidad: El dataset cumple con los criterios de integridad necesarios para la siguiente fase de la metodología CRISP-DM.

5. Resumen, Próximos Pasos y Preguntas Emergentes

Resumen de logros hasta ahora: Durante esta segunda etapa de la metodología CRISP-DM, hemos comprendido a fondo la estructura y calidad de los datos de la red SIMA. Se confirmó la limpieza absoluta del dataset (cero nulos tras la imputación temporal y cero valores negativos) y se generó un perfil estadístico claro. Descubrimos que el PM_{10} tiene una distribución asimétrica positiva y que sus valores atípicos representan contingencias ambientales reales, no errores del sensor. Asimismo, se comprobó una correlación multivariada útil donde factores climáticos (Humedad, Viento) actúan como mitigadores del contaminante.

Qué falta por hacer: El siguiente paso natural es adentrarnos en la fase de Modelado. Específicamente falta: 1. **Ingeniería de Características:** Crear variables de rezago histórico (*lags*) y promedios móviles semanales para capturar la inercia de la contaminación. 2. **Partición Temporal:** Dividir el dataset cronológicamente (Entrenamiento: 2020-2024, Validación: 2025). 3. **Entrenamiento y Evaluación:** Ajustar el modelo de Machine Learning y proyectar los 365 días del año 2026.

Preguntas que han surgido durante la exploración:

- Al observar la marcada diferencia espacial en los boxplots, ¿será más preciso entrenar un único modelo global que tome la estación como variable categórica, o construir 15 sub-modelos independientes (uno para cada estación)?
- Dado que los *outliers* de la asimetría derecha son críticos (días de contingencia), ¿qué función de pérdida (*loss function*) deberíamos usar en el algoritmo para no subestimar estos picos peligrosos para la salud?

6. Anexos y Repositorio

- **Liga al Repositorio de Trabajo:**
 - **GitHub:** https://github.com/INFOAOAA/SIMA_Proyecto.git.

Declaratoria de uso de IA durante el desarrollo del trabajo

Opción B. Se utilizó IA de la siguiente forma:

- **Herramienta:** Gemini (Google).
- **Uso realizado:** Se utilizó como asistente de programación y estructuración. La IA ayudó a redactar el código en Python (con enfoque en pandas, seaborn y matplotlib) bajo el formato de Quarto Document (.qmd). Asimismo, asistió en la estructuración lógica del reporte metodológico CRISP-DM (Etapa 2) y en la sintaxis para el cálculo de estadísticas descriptivas.
- **Secciones donde se utilizó:** En la redacción del objetivo, planteamiento de técnicas estadísticas, generación de tablas de frecuencias/dispersión (Sección 2), código de visualización exploratoria (Sección 3) y rutinas de validación de calidad (Sección 4).
- **Validación realizada por los estudiantes:** Se verificó que el código Python procesara correctamente el archivo CSV del proyecto, revisando visualmente los gráficos generados y cotejando

que los estadísticos descriptivos (media, nulos, rangos) coincidieran con el conocimiento empírico de la base de datos de calidad del aire. **Confirmando que revisé, verifiqué y asumo la total responsabilidad del contenido final entregado en esta actividad.**