



Actividad 1.7

Componentes principales

ANGEL RUBEN GALINDO ALVAREZ A00228356

MA2003B Análisis Multivariado | Blanca Rosa Ruiz Hernández
Raúl Gómez Muñoz

Table of contents

Parte I: Valores y Vectores Propios	2
Análisis de la varianza explicada	4
Ecuaciones de las componentes principales	4
Combinaciones lineales con la matriz de correlaciones	5
Comprobación de Varianza Total	5
Parte II: Gráficas y Puntuaciones (Scores)	6
Interpretación de los gráficos y puntuaciones	13
Exploración del comando princomp()	14
Parte III: Análisis Visual con FactoMineR	14
Opciones del comando PCA()	24
Interpretación de los gráficos	24
Parte IV: Conclusiones y Comparación	25
Comparación de las matrices S y R	25
Variables con mayor contribución y combinaciones finales	26
Interpretación de resultados	26
Declaratoria de uso de IA durante el desarrollo del trabajo	26

A partir de los datos sobre indicadores económicos y sociales de 96 países (países_mundo.csv) hacer una análisis de Componentes principales con la matriz de varianzas-covarianzas y la matriz de correlaciones. Compara los resultados y argumenta cuál es mejor según los resultados obtenidos.

Parte I: Valores y Vectores Propios

Primero, cargamos los datos y calculamos las matrices de covarianza (S) y correlación (R).

```
X <- read.csv("países_mundo.csv")
str(X)

'data.frame': 96 obs. of 11 variables:
 $ CrecPobl : num 1 3 4.3 2.5 1.3 1.4 0.6 2 0.3 3 ...
 $ MortInf : int 30 124 21 34 22 6 6 79 8 95 ...
 $ PorcMujeres: int 41 46 13 24 31 43 41 42 40 48 ...
 $ PNB95 : int 2199 4422 133540 44609 278431 337909 216547 28599 250710 2034 ...
 $ ProdElec : int 3903 955 91019 19883 65962 167155 53259 9891 72236 6 ...
 $ LinTelf : int 12 6 96 42 160 510 465 2 457 5 ...
 $ ConsAgua : int 94 57 497 180 1043 933 304 220 917 26 ...
 $ PropBosq : int 53 19 1 2 22 19 47 6 20 45 ...
 $ PropDefor : num 0 0.7 0 0.8 0.1 0 -0.4 4.1 -0.3 1.3 ...
 $ ConsEner : int 341 89 4566 906 1504 5341 3301 64 5120 20 ...
 $ EmisCO2 : num 1.2 0.5 13.1 3 3.5 15.3 7.2 0.2 10.1 0.1 ...

# Matriz de varianzas-covarianzas
S <- cov(X)
# Valores y vectores propios de S
eigen_S <- eigen(S)
# Matriz de correlaciones
R <- cor(X)
# Valores y vectores propios de R
eigen_R <- eigen(R)
# Proporción de varianza explicada
var_explicada_S <- eigen_S$values / sum(eigen_S$values)
var_explicada_R <- eigen_R$values / sum(eigen_R$values)
# Varianza acumulada
var_acumulada_S <- cumsum(var_explicada_S)
var_acumulada_R <- cumsum(var_explicada_R)
```

Table 1: Valores propios y varianza explicada de las matrices S y R

Compo- nente	Eigenva- lue_S	Varianza_S	Acumula- da_S	Eigenva- lue_R	Varian- za_R	Acumula- da_R
CP1	6.163576e+10	90.3454	90.3454	4.0299	36.6353	36.6353

Compo- nente	Eigenva- lue_S	Varianza_S	Acumula- da_S	Eigenva- lue_R	Varian- za_R	Acumula- da_R
CP2	6.581612e+09	9.6473	99.9927	1.9300	17.5454	54.1806
CP3	4.636256e+06	0.0068	99.9995	1.3704	12.4583	66.6389
CP4	3.107232e+05	0.0005	100.0000	0.8645	7.8592	74.4982
CP5	1.216015e+04	0.0000	100.0000	0.7941	7.2195	81.7176
CP6	5.137767e+02	0.0000	100.0000	0.7292	6.6291	88.3467
CP7	3.627885e+02	0.0000	100.0000	0.5713	5.1937	93.5404
CP8	4.542080e+01	0.0000	100.0000	0.3268	2.9709	96.5113
CP9	5.800900e+00	0.0000	100.0000	0.1681	1.5279	98.0392
CP10	1.438000e+00	0.0000	100.0000	0.1463	1.3303	99.3695
CP11	4.768000e-01	0.0000	100.0000	0.0694	0.6305	100.0000

Table 2: Vectores propios de CP1 y CP2 - Matriz de covarianzas S

Variable	CP1	CP2
CrecPobl	0.00000	0.00000
MortInf	-0.00004	-0.00002
PorcMujeres	0.00001	-0.00001
PNB95	0.88804	0.45976
ProdElec	0.45976	-0.88804
LinTelf	0.00035	0.00040
ConsAgua	0.00026	-0.00112
PropBosq	0.00000	0.00001
PropDefor	0.00000	0.00000
ConsEner	0.00255	0.00071
EmisCO2	0.00000	0.00000

```
# Vectores propios de las dos primeras componentes matriz R
vectores_R <- data.frame(
  Variable = colnames(X),
  CP1 = eigen_R$vectors[, 1],
  CP2 = eigen_R$vectors[, 2]
)
knitr::kable(
  vectores_R,
  digits = 5,
  caption = "Vectores propios de CP1 y CP2 - Matriz de correlaciones R"
)
```

Table 3: Vectores propios de CP1 y CP2 - Matriz de correlaciones R

Variable	CP1	CP2
CrecPobl	-0.31412	0.34836
MortInf	-0.39240	-0.04136
PorcMujeres	0.11655	-0.58284
PNB95	0.29539	-0.17691
ProdElec	0.25896	-0.17356
LinTelf	0.44608	-0.02719
ConsAgua	0.09241	0.32061
PropBosq	0.00569	-0.45743
PropDefor	-0.24365	-0.15408
ConsEner	0.41503	0.23286
EmisCO2	0.37453	0.29169

Análisis de la varianza explicada

En la matriz de varianzas-covarianzas, la primera componente principal concentra aproximadamente el 90.35 % de la variabilidad total, mientras que la segunda explica aproximadamente el 9.65 %. En conjunto, las dos primeras componentes representan prácticamente el 100 % de la variabilidad de los datos. Esto indica que es posible reducir la dimensión del problema utilizando únicamente las dos primeras componentes.

Sin embargo, este resultado debe interpretarse con precaución, debido a que las variables originales están medidas en escalas y unidades muy diferentes. Por esta razón, las variables con mayor magnitud numérica tienen una influencia mucho mayor sobre la matriz de covarianzas y, en consecuencia, sobre sus componentes principales.

En la matriz de correlaciones la primera componente explica aproximadamente el 36.64 % de la varianza y la segunda el 17.55 %, acumulando aproximadamente el 54.18 % entre ambas. A diferencia del análisis con la matriz de covarianzas, la variabilidad queda distribuida entre un mayor número de componentes.

En consecuencia, aunque la matriz S concentra un mayor porcentaje de varianza en sus primeras componentes, este resultado está fuertemente influenciado por las diferencias de escala entre las variables. Para comparar de manera equilibrada los indicadores económicos, sociales, ambientales y de infraestructura, resulta más apropiado considerar el análisis basado en la matriz de correlaciones.

Ecuaciones de las componentes principales

```
Z <- scale(X)
head(Z)
```

	CrecPobl	MortInf	PorcMujeres	PNB95	ProdElec	LinTelf
[1,]	-0.7021255	-0.2819859	0.4238371	-0.51157149	-0.48421426	-0.78128591
[2,]	0.9104116	2.6428889	0.9937020	-0.50162972	-0.50605484	-0.81189956

```
[3,]  1.9585607 -0.5620272 -2.7674067  0.07581588  0.16119412 -0.35269478
[4,]  0.5072773 -0.1575232 -1.5137038 -0.32190415 -0.36582469 -0.62821765
[5,] -0.4602450 -0.5309115 -0.7158929  0.72380198 -0.02444339 -0.02614916
[6,] -0.3796181 -1.0287625  0.6517831  0.98980137  0.72525598  1.75964721
      ConsAgua  PropBosq  PropDefor  ConsEner  EmisC02
[1,] -0.72367391  1.2817266 -0.4103133 -0.6758530 -0.6423225
[2,] -0.78806332 -0.4161450  0.1089532 -0.7883889 -0.7763724
[3,] -0.02235139 -1.3150182 -0.4103133  1.2109104  1.6365259
[4,] -0.57401203 -1.2650808  0.1831342 -0.4235402 -0.2976227
[5,]  0.92782750 -0.2663328 -0.3361323 -0.1564906 -0.2018728
[6,]  0.73639952 -0.4161450 -0.4103133  1.5570031  2.0578256
```

Combinaciones lineales con la matriz de correlaciones

Definiendo las variables estandarizadas como

$$Z_i = \frac{X_i - \bar{X}_i}{s_i}$$

las dos primeras componentes principales obtenidas a partir de la matriz de correlaciones se expresan como:

$$CP_1 = -0.314Z_1 - 0.392Z_2 + 0.117Z_3 + 0.295Z_4 + 0.259Z_5 \\ + 0.446Z_6 + 0.092Z_7 + 0.006Z_8 - 0.244Z_9 + 0.415Z_{10} + 0.375Z_{11}$$

y

$$CP_2 = +0.348Z_1 - 0.041Z_2 - 0.583Z_3 - 0.177Z_4 + 0.174Z_5 \\ - 0.027Z_6 + 0.321Z_7 - 0.457Z_8 - 0.154Z_9 + 0.233Z_{10} + 0.292Z_{11}.$$

Observando los valores absolutos de la ecuación del CP_1 , las variables que más aportan a este componente son las Líneas Telefónicas ($|0.446|$), el Consumo de Energía ($|0.415|$) y la Mortalidad Infantil ($| - 0.392|$). En la ecuación del CP_2 , las variables que más aportan a este componente son el porcentaje de mujeres ($| - 0.583|$), la proporción de bosques ($| - 0.457|$) y el crecimiento poblacional ($|0.348|$).

Comprobación de Varianza Total

Para verificar la equivalencia matemática entre la suma de la diagonal de la matriz S y la suma de sus valores propios (λ), ejecutamos la siguiente validación en R:

```
suma_diagonal_S <- sum(diag(S))
suma_eigen_S <- sum(eigen_S$values)

cat("Suma de la diagonal de S (Traza):", suma_diagonal_S, "\n")
```

Suma de la diagonal de S (Traza): 68222335253

```
cat("Suma de los valores propios (eigenvalues):", suma_eigen_S, "\n")
```

Suma de los valores propios (eigenvalues): 68222335253

```
cat("Son idénticos?:", all.equal(suma_diagonal_S, suma_eigen_S), "\n")
```

Son idénticos?: TRUE

Como se observa, la varianza total de los datos originales es idéntica a la suma de las varianzas reproducidas por los componentes principales.

Parte II: Gráficas y Puntuaciones (Scores)


```
library(stats)
cpS <- princomp(X, cor = FALSE)

scores_S <- cpS$scores

plot(
  scores_S[,1],
  scores_S[,2],
  type = "p",
  main = "Scores - Matriz de Covarianzas (S)",
  xlab = "CP1",
  ylab = "CP2"
)

text(
  scores_S[,1],
  scores_S[,2],
  labels = 1:nrow(X),
  pos = 3,
  cex = 0.6
)
```

Scores – Matriz de Covarianzas (S)



```
cpR <- princomp(X, cor = TRUE)

scores_R <- cpR$scores


plot(
  scores_R[,1],
  scores_R[,2],
  type = "p",
  main = "Scores – Matriz de Correlaciones (R)",
  xlab = "CP1",
  ylab = "CP2"
)

text(
  scores_R[,1],
  scores_R[,2],
  labels = 1:nrow(X),
```




```
pos = 3,  
cex = 0.6  
)
```


Scores – Matriz de Correlaciones (R)



```
biplot(cpS, main = "Biplot - Covarianzas")
```



```
biplot(cpR, main = "Biplot - Correlaciones")
```



```
summary(cpS)
```

Importance of components:

	Comp.1	Comp.2	Comp.3	Comp.4
Standard deviation	2.469691e+05	8.070349e+04	2.141953e+03	5.545146e+02
Proportion of Variance	9.034543e-01	9.647298e-02	6.795804e-05	4.554567e-06
Cumulative Proportion	9.034543e-01	9.999273e-01	9.999953e-01	9.999998e-01
	Comp.5	Comp.6	Comp.7	Comp.8
Standard deviation	1.096972e+02	2.254828e+01	1.894754e+01	6.704303e+00
Proportion of Variance	1.782429e-07	7.530916e-09	5.317738e-09	6.657763e-10
Cumulative Proportion	1.000000e+00	1.000000e+00	1.000000e+00	1.000000e+00
	Comp.9	Comp.10	Comp.11	
Standard deviation	2.395922e+00	1.192913e+00	6.869072e-01	
Proportion of Variance	8.502887e-11	2.107843e-11	6.989035e-12	
Cumulative Proportion	1.000000e+00	1.000000e+00	1.000000e+00	

```
cpS$loadings
```

Loadings:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6	Comp.7	Comp.8	Comp.9
CrecPobl									
MortInf						0.992			
PorcMujeres							-0.114	-0.986	
PNB95	-0.888	0.460							
ProdElec	-0.460	-0.888							
LinTelf					-0.992				
ConsAgua				0.999					
PropBosq							-0.992	0.117	
PropDeform									-0.128
ConsEner			-0.997						
EmisCO2									0.989
	Comp.10	Comp.11							
CrecPobl	0.116	0.987							
MortInf									
PorcMujeres									
PNB95									
ProdElec									
LinTelf									
ConsAgua									
PropBosq									
PropDeform	0.986	-0.105							
ConsEner									
EmisCO2	0.120								

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6	Comp.7	Comp.8	Comp.9
SS loadings	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Proportion Var	0.091	0.091	0.091	0.091	0.091	0.091	0.091	0.091	0.091
Cumulative Var	0.091	0.182	0.273	0.364	0.455	0.545	0.636	0.727	0.818
	Comp.10	Comp.11							
SS loadings	1.000	1.000							
Proportion Var	0.091	0.091							
Cumulative Var	0.909	1.000							

`head(cpS$scores)`

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6	Comp.7
[1,]	131634.61	5448.579	1200.4984	-327.2735	33.92489	-25.960349	-24.94858
[2,]	131016.54	9088.434	1458.4961	-349.6596	35.86571	65.897369	11.19761
[3,]	-25064.80	-11525.605	-2642.9665	-137.0437	239.37443	-19.421081	15.28344
[4,]	86624.44	10756.567	751.1743	-264.6011	52.66824	-20.261633	26.30074
[5,]	-142205.52	77338.805	747.4963	613.3208	33.45819	-20.970244	1.76278
[6,]	-241558.95	14824.119	-2883.9008	260.4086	-77.32476	7.513569	7.03821

	Comp.8	Comp.9	Comp.10	Comp.11
[1,]	-3.0995462	-0.7780467	-1.3689922	-0.503460602
[2,]	-4.2497698	0.7813874	-0.3689436	-0.001616109
[3,]	14.2989501	1.5504109	0.1871852	0.324429033
[4,]	7.9254902	-0.2345264	0.2001111	-0.468251132
[5,]	-0.1150218	-0.5967002	-0.5657178	-0.299886888
[6,]	-4.0051186	4.1384749	0.9728609	0.528789950

```
summary(cpR)
```

Importance of components:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5
Standard deviation	2.0074559	1.3892415	1.1706456	0.92979351	0.8911456
Proportion of Variance	0.3663526	0.1754538	0.1245828	0.07859236	0.0721946
Cumulative Proportion	0.3663526	0.5418065	0.6663893	0.74498164	0.8171762

	Comp.6	Comp.7	Comp.8	Comp.9	Comp.10
Standard deviation	0.85393206	0.75584728	0.57166507	0.40996153	0.38252868
Proportion of Variance	0.06629091	0.05193683	0.02970918	0.01527895	0.01330256
Cumulative Proportion	0.88346715	0.93540398	0.96511315	0.98039210	0.99369467

	Comp.11
Standard deviation	0.263360314
Proportion of Variance	0.006305332
Cumulative Proportion	1.000000000

```
cpR$loadings
```

Loadings:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6	Comp.7	Comp.8	Comp.9
CrecPobl	0.314	0.348		0.440	0.330	0.184	0.163		0.522
MortInf	0.392		0.178	0.134			0.640	0.323	-0.290
PorcMujeres	-0.117	-0.583	-0.167		-0.187	-0.168	0.531		0.236
PNB95	-0.295	-0.177	0.533	0.262	0.141		-0.149	0.449	-0.370
ProdElec	-0.259	-0.174	0.614	0.174			0.108	-0.503	0.307
LinTelf	-0.446		-0.152					0.570	0.447
ConsAgua		0.321	0.370	-0.736		0.309	0.236		
PropBosq		-0.457	-0.165		0.415	0.754			
PropDefor	0.244	-0.154		-0.337	0.733	-0.509			
ConsEner	-0.415	0.233	-0.206		0.231		0.271		
EmisCO2	-0.375	0.292	-0.206	0.148	0.240		0.335	-0.310	-0.377

	Comp.10	Comp.11
CrecPobl	0.347	0.101
MortInf	-0.390	-0.175
PorcMujeres	0.429	0.168
PNB95	0.349	0.152

```

ProdElec    -0.338  -0.124
LinTelf     -0.210  -0.450
ConsAgua     0.206
PropBosq
PropDefor
ConsEner    -0.361   0.679
EmisCO2     0.288  -0.467

```

```

                Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9
SS loadings    1.000  1.000  1.000  1.000  1.000  1.000  1.000  1.000  1.000
Proportion Var 0.091  0.091  0.091  0.091  0.091  0.091  0.091  0.091  0.091
Cumulative Var 0.091  0.182  0.273  0.364  0.455  0.545  0.636  0.727  0.818
                Comp.10 Comp.11
SS loadings    1.000  1.000
Proportion Var 0.091  0.091
Cumulative Var 0.909  1.000

```

```
head(cpR$scores)
```

```

                Comp.1    Comp.2    Comp.3    Comp.4    Comp.5    Comp.6
[1,]  0.7289094 -1.3912622 -0.84817198 -0.07359147 -0.5000039  0.80784207
[2,]  2.5818300 -0.6652926  0.01799326  0.91386383 -0.7027444 -0.30411695
[3,] -0.3975834  3.7230227  0.30969030  1.55474375  1.0448741 -0.03554062
[4,]  1.1420947  1.3912504  0.11144073  0.51586437 -0.1904612 -0.83711734
[5,] -0.4934213  0.5343415  0.82203198 -0.64771527 -0.3431503  0.21957753
[6,] -3.4647057  0.6374099 -0.02937816 -0.02161926  0.4921950 -0.28913091
                Comp.7    Comp.8    Comp.9    Comp.10    Comp.11
[1,] -0.7261548 -0.5532956 -0.3721203  0.009735613  0.22337369
[2,]  1.7717932  0.6320579 -0.1014033 -0.190772201 -0.09523019
[3,] -0.5334868 -0.5001883 -0.1705403 -0.086366759  0.04742182
[4,] -1.0646469 -0.1493179 -0.1485538 -0.216248463 -0.11861754
[5,] -0.7830986  0.2619688 -0.3573453  0.231231778  0.12623452
[6,]  0.8748499  0.1764360  0.1561876  0.512396414 -0.30974184

```

Interpretación de los gráficos y puntuaciones

En los gráficos elaborados con la matriz de covarianzas (S), las variables con valores numéricos muy grandes como PNB95 o ProdElec dominan por completo el análisis, haciendo que los demás países y variables se amontonen. Al usar la matriz de correlaciones (R), se estandarizan los datos y vemos una distribución más equilibrada en el espacio.

En el biplot, LinTelf, ConsEner y EmisCO2 presentan una orientación asociada positivamente con CP1, mientras que MortInf presenta una orientación opuesta. Esto es consistente con una asociación negativa entre estas variables y la mortalidad infantil en el espacio representado por las dos primeras componentes.

Posibles datos atípicos:

- Los países 16 y 37 se alejan mucho en el eje del CP1, lo que indica un nivel de infraestructura muy por encima del promedio.
- Los países 31 y 48 son valores atípicos en el eje del CP2 por sus proporciones particulares en variables demográficas como PorcMujeres.

Exploración del comando princomp()

Al utilizar la función `princomp()` de la librería `stats`, se exploraron los siguientes subcomandos para facilitar el análisis: - `summary(cpS)`: Nos proporciona un resumen estadístico rápido, mostrando la desviación estándar, la proporción de varianza explicada y la varianza acumulada por cada componente principal. - `cpS$loadings`: Muestra la matriz de cargas (vectores propios), indicando el peso que tiene cada variable original en la construcción de los componentes. Para facilitar la lectura, R oculta visualmente los valores muy cercanos a cero. - `cpS$scores`: Almacena la matriz con las coordenadas exactas de las observaciones (los 96 países) transformadas al nuevo espacio de los componentes principales, lo cual nos permite graficarlos.

El signo global de un componente es arbitrario, por ello algunos resultados de `princomp()` pueden presentar todos los coeficientes con signo contrario respecto a `eigen()`, sin alterar la interpretación ni la varianza explicada.

Parte III: Análisis Visual con FactoMineR


```
library(FactoMineR)
library(factoextra)

pca_S <- PCA(
  X,
  scale.unit = FALSE,
  graph = FALSE
)


pca_R <- PCA(
  X,
  scale.unit = TRUE,
  graph = FALSE
)

fviz_pca_ind(
  pca_S,
  addEllipses = TRUE,
  repel = FALSE
```


)




```
fviz_pca_var(  
  pca_S,  
  repel = TRUE  
)
```


```
fviz_screplot(  
  pca_S,  
  addlabels = TRUE  
)
```




```
fviz_contrib(  
  pca_S,  
  choice = "var",  
  axes = 1  
)
```




```
fviz_contrib(  
  pca_S,  
  choice = "var",  
  axes = 2  
)
```




```
fviz_pca_ind(  
  pca_R,  
  addEllipses = TRUE,  
  repel = FALSE  
)
```




```
fviz_pca_var(  
  pca_R,  
  repel = TRUE  
)
```




```
fviz_screplot(  
  pca_R,  
  addlabels = TRUE  
)
```



```
fviz_contrib(  
  pca_R,  
  choice = "var",  
  axes = 1  
)
```



```
fviz_contrib(  
  pca_R,  
  choice = "var",  
  axes = 2  
)
```

Opciones del comando `PCA()`

La función `PCA()` de `FactoMineR` permite controlar diferentes aspectos del análisis. Una opción particularmente importante es `scale.unit`. Cuando se establece como `TRUE`, las variables son estandarizadas antes de calcular las componentes, por lo que el análisis corresponde al enfoque basado en la matriz de correlaciones. Cuando se establece como `FALSE`, las variables conservan sus unidades originales y el análisis corresponde al enfoque basado en la matriz de varianzas-covarianzas.

La función también permite establecer si se desean generar gráficos automáticamente mediante `graph`, así como incorporar variables suplementarias que no participan directamente en la construcción de las componentes principales. Estas opciones facilitan la exploración y posterior interpretación del análisis.

Interpretación de los gráficos

En el análisis basado en la matriz de covarianzas, las variables que presentan mayores escalas numéricas tienen una influencia considerable sobre las componentes principales. Esto provoca

que la representación de los países esté dominada principalmente por las variables con mayor variabilidad absoluta. Por esta razón, la interpretación conjunta de los indicadores resulta menos equilibrada.

En el análisis basado en la matriz de correlaciones, las variables fueron estandarizadas antes de realizar el PCA. La representación resulta más equilibrada y permite observar con mayor claridad las relaciones existentes entre los diferentes indicadores.

En el gráfico de variables, las variables que apuntan en direcciones similares presentan asociaciones positivas, mientras que las que apuntan en direcciones opuestas presentan asociaciones negativas. Asimismo, una mayor cercanía de una variable a la circunferencia de correlaciones indica una mejor representación de dicha variable en el plano formado por las dos primeras componentes.

En el gráfico de individuos, los países ubicados cerca unos de otros presentan perfiles similares respecto a los indicadores considerados. Por el contrario, los países alejados del centro de la distribución presentan características diferentes respecto al conjunto de observaciones.

Algunos países aparecen alejados de la concentración principal de observaciones y pueden considerarse observaciones potencialmente atípicas. Sin embargo, su posición en el gráfico no es suficiente por sí sola para afirmar que se trata de errores o valores atípicos estadísticos; sería necesario revisar sus valores originales para determinar qué indicadores son responsables de su posición.

Posibles datos atípicos:

- Los países 16 y 37 se alejan mucho en el eje del CP1, lo que indica un nivel de infraestructura muy por encima del promedio.
- Los países 31 y 48 son valores atípicos en el eje del CP2 por sus proporciones particulares en variables demográficas como PorcMujeres.

En el análisis de correlaciones, las variables LinTelf, ConsEner y EmisCO2 presentan una relación positiva importante con la primera componente, mientras que MortInf presenta una relación negativa. En la segunda componente destacan especialmente PorcMujeres y PropBosq, mientras que CrecPobl también presenta una contribución importante.

Parte IV: Conclusiones y Comparación

Comparación de las matrices S y R

Los resultados muestran una diferencia importante entre realizar el análisis de componentes principales utilizando la matriz de varianzas-covarianzas y utilizar la matriz de correlaciones.

Con la matriz de varianzas-covarianzas, la primera componente explica aproximadamente el 90.35 % de la variabilidad total y la segunda aproximadamente el 9.65 %. Aunque esto permite representar prácticamente toda la variabilidad con dos componentes, el resultado está fuertemente condicionado por las diferentes escalas de medición de las variables. En particular, las variables con mayor variabilidad absoluta tienen una influencia mucho mayor en la construcción de las componentes.

Por otro lado, al utilizar la matriz de correlaciones, las variables son estandarizadas y cada indicador participa en una escala comparable. La primera componente explica el 36.64 % y la segunda el 17.55 %, acumulando el 54.18 % de la variabilidad. Aunque se requiere un mayor número de componentes para explicar una proporción elevada de la varianza, este análisis permite representar de manera más equilibrada los diferentes indicadores económicos, sociales, ambientales y de infraestructura.

Por lo anterior se considera más apropiado utilizar el análisis basado en la matriz de correlaciones, ya que resulta más útil para interpretar las relaciones existentes entre los indicadores y construir componentes que representen conjuntamente diferentes dimensiones del desarrollo de los países.

Variables con mayor contribución y combinaciones finales

Basándonos en los coeficientes absolutos y los gráficos de la matriz R, las variables que más contribuyen son: - Para el CP1: LinTelf (0.446), ConsEner (0.415), MortInf (0.392) y EmisCO2 (0.375). - Para el CP2: PorcMujeres (0.583), PropBosq (0.457) y CrecPobl (0.348).

Las combinaciones finales recomendadas para el análisis son:

$$CP_1 = -0.314Z_1 - 0.392Z_2 + 0.117Z_3 + 0.295Z_4 + 0.259Z_5 \\ + 0.446Z_6 + 0.092Z_7 + 0.006Z_8 - 0.244Z_9 + 0.415Z_{10} + 0.375Z_{11}$$

y

$$CP_2 = +0.348Z_1 - 0.041Z_2 - 0.583Z_3 - 0.177Z_4 - 0.174Z_5 \\ - 0.027Z_6 + 0.321Z_7 - 0.457Z_8 - 0.154Z_9 + 0.233Z_{10} + 0.292Z_{11}.$$

Interpretación de resultados

- El CP1 puede interpretarse como un **“Índice de Infraestructura y Desarrollo”**, ya que contrapone el nivel tecnológico y económico de un país contra sus niveles de mortalidad infantil. Valores altos describen naciones con amplia cobertura de servicios.
- El CP2 puede interpretarse como un **“Índice Demográfico-Forestal”**, fuertemente marcado por la participación laboral de las mujeres y la cobertura de bosques en contraste con el crecimiento poblacional.

Declaratoria de uso de IA durante el desarrollo del trabajo

Opción B. Se utilizó IA especificando lo siguiente:

- Herramienta: Gemini (modelo de lenguaje de Inteligencia Artificial).
- Uso realizado: Se utilizó como tutor y asistente de revisión para apoyar en el análisis estadístico de Componentes Principales (PCA). La IA ayudó a verificar el cumplimiento de cada rubro y a estructurar la retroalimentación sobre la justificación entre la matriz de covarianzas y

la de correlaciones, así como apoyo en el significado de cada gráfico de manera teórica y posteriormente práctica con los datos de la actividad.

- Secciones donde se utilizó: En la etapa de revisión final de la estructura del documento, en la parte III apoyando con los gráficos y en la validación de cumplimiento de los requisitos de la tarea (Partes I a la IV).
- Validación realizada por los estudiantes: Se leyó críticamente la retroalimentación generada para confirmar que los argumentos y conclusiones presentadas en el documento fueran estadísticamente congruentes.
- Confirmación: Confirmando que la información analizada con ayuda de la IA fue revisada y verificada en su totalidad, y asumo la completa responsabilidad del contenido final entregado y las conclusiones expuestas en este trabajo.