



Predicción de PM_{10} en la Zona Metropolitana de Monterrey

Análisis Factorial de Variables Meteorológicas y Modelado Horario SARIMAX

ANGEL RUBÉN GALINDO ÁLVAREZ & A00228356

JORGE RAÚL MARTÍNEZ RAMÍREZ & A01286802

ROBERTO PÉREZ CASTILLO & A01286834

ALEJANDRO TORRES & A00840943

EQUIPO 6

MA2003B Análisis Multivariado | Blanca Rosa Ruiz Hernández

Raúl Gómez Muñoz

*		Resumen
	Tabla de contenidos	Resumen
*		1
Resumen		1
Resumen		1
Introducción y Justificación		2
Problemática y Objetivos		2
Problemática		2
Objetivo General		2
Objetivos Específicos		2
Contexto Geográfico y Factores Ambientales de las Estaciones		3
Preparación de Datos y Metodología		3
Depuración y Tratamiento Normativo de los Datos		3
Justificación de Decisiones Metodológicas Clave		4
Descarte del Agrupamiento por k -means		4
Preservación de la Resolución Horaria		4
Selección Espacial por Distancia de Mahalanobis		4
Reducción de Dimensionalidad por Análisis Factorial		4
Protocolo de Filtrado e Identificación Local		4
Estructura Factorial Particular por Estación		5
Puntuaciones Factoriales (<i>Factor Scores</i>)		5
Modelación SARIMAX, Resultados y Diagnóstico de Residuos		5
Formulación del Modelo SARIMAX		5
Selección de Ordenes y Evaluación por Estación		6
Desempeño Ajustado por Microclima		6
Diagnóstico y Validación de Residuos		7
Conclusiones y Recomendaciones		7
Recomendaciones para el SIMA		8
Líneas de Investigación Futura		8
Referencias		8
Anexos		9
		El material particulado menor a 10 micrómetros (PM_{10}) representa el principal contaminante atmosférico crítico en la Zona Metropolitana de Monterrey (ZMM) (Ramírez-Gómez et al., 2025), superando de forma recurrente los límites establecidos por la norma NOM-025-SSA1 (Secretaría de Salud, 2021). Este estudio desarrolla un marco predictivo multivariado y autorregresivo de resolución horaria ($s = 24$) para proveer al Sistema de Monitoreo Ambiental (SIMA) una herramienta funcional de alerta temprana a corto plazo (horizonte de 7 horas). El diseño metodológico integra cuatro etapas principales: 1. Filtro y depuración: Validación de series horarias continuas (2020–2025) bajo el criterio de disponibilidad $\geq 75\%$ diario, corrección de anomalías físicas y estabilización de varianza mediante la transformación Yeo-Johnson. 2. Selección espacial por interdependencia: Aplicación de la Distancia de Mahalanobis sobre la matriz de covarianza agrupada de 15 estaciones del SIMA. Se descartó el agrupamiento por k-means debido a la pérdida de comportamiento extremo, identificando un triplete de estaciones que maximizan la separación combinada de 19.97: García (NO₂), Cadereyta (SE3) y Pesquería (NE3). 3. Reducción de dimensionalidad: Análisis Factorial Exploratorio (AFE) independiente por estación mediante el método de Ejes Principales y rotación Varimax, extrayendo de 2 a 3 factores latentes sintéticos (combustión, dinámica fotoquímica y humedad/estabilidad térmica) que eliminaron la multicolinealidad y mostraron los factores latentes del comportamiento de cada estación. 4. Modelado predictivo de series de tiempo: Estimación de modelos SARIMAX con variables exógenas contenidas en los factores latentes, con una escala horaria. Los resultados en la ventana de evaluación (7 horas) demostraron un muy buen desempeño en la estación NO₂ con un Error Porcentual Absoluto Medio (MAPE) de 18.10% y MAE de 13.31 $\mu g/m^3$. En las estaciones SE3 y NE3 se registraron MAPEs del 23.22% y 63.54%, respectivamente. El diagnóstico de residuos confirmó la eliminación exitosa de la autocorrelación serial (Durbin-Watson

≈ 2.01 en NO_2), aunque la presencia de leptocurtosis confirma que los picos atípicos de contaminación deben ser gestionados mediante el límite superior del intervalo de confianza al 95 %. Se entrega un pipeline totalmente reproducible para su implementación en la infraestructura del SIMA.

Introducción y Justificación

La contaminación por material particulado menor a 10 micrómetros (PM_{10}) en la Zona Metropolitana de Monterrey (ZMM) constituye un desafío ambiental agravado por su orografía. La cuenca semiárida del valle, circunscrita por formaciones de gran elevación como la Sierra Madre Oriental, el Cerro de las Mitras y el Cerro de la Silla, restringe la circulación del aire e intensifica la acumulación de contaminantes, particularmente durante las inversiones térmicas invernales. (González-Santiago et al., 2011).

Esta condición geográfica interactúa con un parque vehicular creciente y una concentrada base industrial —siderúrgica, cementera, química y energética—. Como consecuencia, las concentraciones diarias de PM_{10} superan de manera recurrente los límites de la norma NOM-025-SSA1, con el consecuente impacto en la salud pública derivado del incremento en ingresos hospitalarios por padecimientos respiratorios y cardiovasculares (Cerón-Bretón et al., 2021).

Actualmente, la red automatizada de 15 estaciones del Sistema de Monitoreo Ambiental (SIMA) opera bajo un esquema reactivo que emite alertas una vez rebasados los umbrales normativos. Modificar este enfoque hacia una gestión preventiva exige herramientas predictivas con capacidad de anticipación a escala horaria.

Este trabajo justifica su desarrollo en la necesidad de un marco analítico reproducible e interpretable. En lugar de recurrir a arquitecturas opacas de caja negra, se integra la Distancia de Mahalanobis para la selección espacial de sitios, el Análisis Factorial Exploratorio (AFE) para mitigar la multicolinealidad entre covariables, y la modelación autorregresiva SARIMAX. Con ello, se provee al SIMA de un sistema de alerta temprana fundamentado estadísticamente para respaldar la toma de decisiones operativas.

Problemática y Objetivos

Problemática

El pronóstico operativo de PM_{10} a escala horaria presenta tres barreras metodológicas fundamentales:

1. **Heterogeneidad y redundancia espacial:** Las 15 es-

taciones de la red SIMA capturan dinámicas microclimáticas diferenciadas. Promediar la red o agrupar estaciones mediante algoritmos estandarizados como k -means diluye los comportamientos extremos necesarios para prever contingencias.

2. **Multicolinealidad entre predictores:** Los contaminantes precursores (CO , NO , NO_2 , SO_2 , O_3) y los parámetros meteorológicos (temperatura, humedad relativa, velocidad y dirección del viento) presentan interdependencias severas que desestabilizan las estimaciones por regresión múltiple convencional.
3. **Estructura estacional diurna:** Las series temporales de calidad del aire exhiben autocorrelación espacial y patrones estacionales diurnos marcados ($s = 24$), influenciados por las horas pico de tráfico vehicular y la dinámica del límite de la capa de mezcla atmosférica.

Objetivo General

Desarrollar y validar un marco multivariado de modelación autorregresiva a resolución horaria ($s = 24$) para pronosticar las concentraciones de PM_{10} en tres estaciones pivote de la ZMM (García - NO_2 , Cadereyta - SE_3 y Pesquería - NE_3), utilizando la Distancia de Mahalanobis para la selección, Análisis Factorial Exploratorio para la síntesis de variables exógenas y el modelo SARIMAX para la predicción a corto plazo (horizonte de 7 horas).

Objetivos Específicos

- Consolidar y validar la base de datos horaria del SIMA (2020–2025) aplicando criterios de representatividad temporal ($\geq 75\%$ de registros válidos diarios) bajo la norma NOM-025-SSA1.
- Identificar el triplete de estaciones con mayor contraste multivariado mediante la maximización de la Distancia de Mahalanobis sobre la matriz de covarianza agrupada (S_{pooled}^{-1}).
- Reducir la dimensionalidad de las variables meteorológicas y contaminantes precursores mediante Análisis Factorial Exploratorio (AFE) con rotación Varimax, generando factores latentes ortogonales que eliminen la multicolinealidad.
- Formular y evaluar los modelos SARIMAX $(p, d, q) \times (P, D, Q)_{24}$ para las tres estaciones seleccionadas, diagnosticando la significancia de los factores exógenos y la estructura de los residuos en la ventana de evaluación de 7 horas.

Contexto Geográfico y Factores Ambientales de las Estaciones

La representatividad del modelo se sustenta en la heterogeneidad geográfica de las tres estaciones seleccionadas mediante la Distancia de Mahalanobis, por lo cual entraremos en detalle las características geográficas de cada una de las estaciones:

- **Estación NO2 (García):** Localizada en el extremo poniente de la ZMM (25.793°N, -100.583°W). Se ubica en una zona semiárida adyacente al cañón de la Huasteca y al área de extracción de minerales no metálicos (pedreras). Su perfil ambiental se caracteriza por la resuspensión de polvo inorgánico propiciada por vientos intensos estancados y por emisiones derivadas del tráfico de carga pesada en la carretera Monterrey-Salttillo.
- **Estación SE3 (Cadereyta):** Situada en el sector suroriente de la cuenca metropolitana (25.586°N, -99.996°W). Está fuertemente influenciada por la Refinería de PEMEX "Héctor R. Lara Sosa" e industrias químicas aledañas. Registra niveles elevados de SO_2 y precursores de azufre que, al interactuar con la humedad relativa de la cuenca del río San Juan, favorecen la formación de aerosoles secundarios.
- **Estación NE3 (Pesquería):** Ubicada en el corredor industrial de reciente expansión (25.782°N, -100.063°W). Corresponde a un entorno dominado por complejos siderúrgicos, automotrices y un crecimiento urbano acelerado. Muestra concentraciones base moderadas con incrementos abruptos asociados a los ciclos operacionales industriales y al transporte logístico.




Figura 1: Ubicación geográfica de las estaciones analizadas del SIMA en la ZMM.




Figura 2: Distribución mensual de PM_{10} para el triplete representativo (2020–2025). La elevación de las medianas durante los meses de invierno evidencia el efecto de las inversiones térmicas sobre la acumulación de contaminantes.

Preparación de Datos y Metodología

Depuración y Tratamiento Normativo de los Datos

La base de datos original comprende registros horarios del SIMA acumulados entre los años 2020 y 2025 para 15 estaciones de monitoreo. Para garantizar la validez estadística y física de los análisis, se ejecutó un protocolo de depuración estructurado en tres fases:

1. **Filtrado de Anomalías Físicas:** Se identificaron y corrigieron inconsistencias atribuibles a fallas de calibración o lecturas fuera de rango operacional en los sensores. Específicamente, se acotaron los parámetros meteorológicos a límites físicamente coherentes para la región (temperaturas entre -10 °C y 50 °C; velocidades de viento inferiores a 100 km/h). Las lecturas anómalas (e.g., -57.8 °C o vientos de 158.8 km/h) se trataron mediante un algoritmo de arrastre temporal (*forward fill*) acotado por estación.
2. **Criterio de Representatividad Normativa:** Conforme a las directrices de la norma NOM-025-SSA1 (Secretaría de Salud, 2021), se validaron únicamente los días que contaran con un mínimo de 18 horas de registro continuo ($\geq 75\%$ de disponibilidad diaria). Para ventanas faltantes de corta duración (≤ 3 horas), se aplicó interpolación lineal intra-estacional.
3. **Estabilización de Varianza (Transformación Yeo-Johnson):** Dado que la distribución de PM_{10} exhibe una asimetría positiva severa y heterocedasticidad, se aplicó la transformación Yeo-Johnson sobre la variable respuesta para aproximar la normalidad y estabilizar la varianza residual en el modelado posterior.

Justificación de Decisiones Metodológicas Clave

Descarte del Agrupamiento por k -means

En fases preliminares del proyecto se exploró el uso de agrupamiento mediante k -means para categorizar las estaciones de la red. Sin embargo, el algoritmo de clustering promedia los comportamientos de las estaciones asignadas a un mismo conglomerado. En el contexto de contingencias ambientales, este suavizado destruye la variabilidad de los picos atípicos en estaciones expuestas a dinámicas microclimáticas particulares (tales como las pederas en NO₂ o la refinería en SE3). Por ello, se descartó el agrupamiento en favor de la Distancia de Mahalanobis.

Preservación de la Resolución Horaria

Asimismo, se descartó la agregación de datos a promedios diarios de 24 horas. La dinámica de PM_{10} en la ZMM está fuertemente acoplada a ciclos estacionales diurnos ($s = 24$), como el tráfico en horas pico y la formación de la capa de mezcla nocturna. Reducir la serie a datos diarios elimina la capacidad del modelo para operar como un verdadero Sistema de Alerta Temprana en ventanas de oportunidad operativas (e.g., pronósticos a 7 horas).

Selección Espacial por Distancia de Mahalanobis

Para seleccionar las tres estaciones centinela que maximicen la heterogeneidad y representatividad multivariada sin incurrir en redundancia espacial, se aplicó la Distancia de Mahalanobis sobre los vectores de medias de las 15 estaciones de la red.

La distancia multivariada entre una estación i y una estación j se define como:

$$D_M(\mathbf{u}_i, \mathbf{u}_j) = \sqrt{(\mathbf{u}_i - \mathbf{u}_j)^T S_{\text{pooled}}^{-1} (\mathbf{u}_i - \mathbf{u}_j)}$$

donde $\mathbf{u}_i$ representa el vector de medias de las variables ambientales de la estación i , y S_{pooled}^{-1} es la inversa de la matriz de covarianza agrupada. Se calculó la matriz de distancias por pares y se formuló un problema de optimización combinatoria para hallar el triplete de estaciones que maximiza la separación espacial conjunta:

$$\text{Max } \mathcal{D} = D_M(\mathbf{u}_1, \mathbf{u}_2) + D_M(\mathbf{u}_1, \mathbf{u}_3) + D_M(\mathbf{u}_2, \mathbf{u}_3)$$

El algoritmo identificó como solución óptima al triplete conformado por NO₂ (García), SE3 (Cadereyta) y NE3 (Pesquería), alcanzando una separación combinada de 19.97. Este conjunto captura los tres extremos de la cuenca metropolitana: el poniente mineral, el suroriente

industrial-petroquímico y el nororiente de manufactura en expansión.

Reducción de Dimensionalidad por Análisis Factorial

Las covariables meteorológicas y de contaminación presentan colinealidad cruzada. Para evitar la desestabilización de las estimaciones en los modelos predictivos, se implementó un Análisis Factorial Exploratorio (AFE) de forma completamente independiente y dedicada para cada una de las tres estaciones seleccionadas.




Figura 3: Matriz de correlación entre los contaminantes y las variables meteorológicas retenidas (PM_{10} , $PM_{2.5}$, $TOUT$, RH , WSR , PRS). La marcada interdependencia entre predictores justifica la reducción de dimensionalidad mediante el AFE.

Esta aproximación individualizada responde a que las dinámicas físicas y químicas varían según la ubicación geográfica:

- Las tasas de dispersión, reacciones fotoquímicas y fuentes de emisión locales generan estructuras de covarianza distintas en cada punto de la cuenca.
- Tratar la red con un AFE global forzaría combinaciones lineales homogéneas que distorsionarían los predictores reales en microclimas específicos.

Protocolo de Filtrado e Identificación Local

Para cada estación se aplicó un proceso iterativo en dos fases:

- Adecuación Muestral Local (KMO):** Se evaluó el índice Kaiser-Meyer-Olkin por variable. Aquellas variables con $KMO < 0.50$ fueron descartadas secuencialmente hasta lograr un KMO global aceptable (> 0.7).
- Evaluación de Unicidad (Uniqueness):** Tras la extracción por Ejes Principales (*Principal Axis*), se eliminaron las variables con varianza no explicada o unicidad

$u^2 \geq 0.90$, reteniendo únicamente los predictores con suficiente comunalidad.

- **Rotación Varimax y Extracción:** Se determinó la cantidad óptima de factores mediante el criterio de Kaiser ($\lambda \geq 1$) combinado con la caída relativa del *Scree Plot*, aplicando rotación ortogonal Varimax.

Estructura Factorial Particular por Estación

Como resultado del AFE independiente, cada estación consolidó un número y una composición de factores latentes completamente diferenciada:

1. Estación NO2 (García - Poniente)

Debido a la alta variabilidad eólica del cañón de la Huasteca, los gases de combustión primaria (NO , NO_2 , CO) exhibieron una elevada unicidad ($u^2 > 0.87$) y fueron descartados por el algoritmo de filtrado. Se retuvieron 2 factores latentes basados en 5 variables meteorológicas y fotoquímicas ($KMO = 0.7010$):

- **Factor_1_Photochemical** ($\lambda = 2.15$): Carga fuertemente sobre O_3 (0.787), WSR (0.573) y RH (-0.624). Captura los episodios de inestabilidad fotoquímica y dispersión por viento.
- **Factor_2_Temperature** ($\lambda = 0.60$): Dominado por la temperatura $TOUT$ (-0.770) y la presión barométrica PRS (0.721), representando la dinámica micrometeorológica local.

El *scree plot* y el diagrama de cargas rotadas de esta estación se muestran en el Anexo (Figura 11 y Figura 14).

2. Estación SE3 (Cadereyta - Suroriente)

Dada la fuerte influencia persistente de la refinería e industria pesada, se retuvieron 11 variables sintéticas distribuidas en 3 factores latentes ($KMO = 0.7120$):

- **Factor_1_Temperature** ($\lambda = 2.82$): Representa el perfil térmico y de estabilidad barométrica ($TOUT$: -0.924, PRS : 0.617).
- **Factor_2_Combustion** ($\lambda = 1.41$): Agrupa las emisiones primarias directas con altas cargas en NO_2 (0.751), NO (0.692), $PM_{2.5}$ (0.631) y CO (0.433).
- **Factor_3_Photochemical** ($\lambda = 0.72$): Sintetiza la interacción entre la radiación solar SR (0.675), O_3 (0.765) y precursores de azufre SO_2 (0.421).

El *scree plot* y el diagrama de cargas rotadas de esta estación se muestran en el Anexo (Figura 12 y Figura 15).

3. Estación NE3 (Pesquería - Nororiente)

En el corredor industrial-urbano de reciente expansión se retuvieron 8 variables organizadas en 3 factores latentes ($KMO = 0.7065$):

- **Factor_1_Moisture** ($\lambda = 2.99$): Dominado de forma casi exclusiva por la humedad relativa RH (0.995) e inversamente por O_3 (-0.644), capturando eventos de condensación e inversión térmica.
- **Factor_2_Combustion** ($\lambda = 0.94$): Refleja la actividad del transporte de carga e industria pesada (NO_2 : 0.859, NO : 0.490, WDR : 0.369).
- **Factor_3_Temperature** ($\lambda = 0.72$): Sintetiza las fluctuaciones de temperatura $TOUT$ (-0.882) y presión PRS (0.649).

El *scree plot* y el diagrama de cargas rotadas de esta estación se muestran en el Anexo (Figura 13 y Figura 16).

Puntuaciones Factoriales (Factor Scores)

Las puntuaciones continuas ortogonales ($r = 0$ inter-factor por estación) se calcularon para cada registro horario t mediante el método de regresión:

$$F_{k,t} = Z_{k,t} \cdot R_k^{-1} L_k$$

donde $k \in \{NO2, SE3, NE3\}$, $Z_{k,t}$ es la matriz de variables estandarizadas retenidas en la estación k , R_k^{-1} es la matriz de correlaciones invertida y L_k es la matriz de cargas factoriales rotadas. Estas series temporales sintéticas sirven como variables exógenas (X_t) libres de multicolinealidad dentro de la subsecuente modelación SARIMAX de cada sitio.

Modelación SARIMAX, Resultados y Diagnóstico de Residuos

Formulación del Modelo SARIMAX

Para predecir las concentraciones horarias de PM_{10} incorporando la inercia temporal y las dinámicas meteorológicas y contaminantes, se estructuró un modelo autorregresivo integrado de media móvil con variables exógenas y componente estacional: SARIMAX (p, d, q) $\times$ (P, D, Q)₂₄.

La especificación matemática del modelo para la variable transformada Y_t (mediante Yeo-Johnson) en la estación k se expresa como:

$$\begin{aligned} & \Phi_P(B^{24})\phi_p(B)(1-B)^d(1-B^{24})^D Y_t \\ &= \sum_{m=1}^K \gamma_m F_{m,t} + \Theta_Q(B^{24})\theta_q(B)\epsilon_t \end{aligned} \quad (1)$$

donde:

- B es el operador de retardo (*backshift*), tal que $B^j Y_t = Y_{t-j}$.
- $\phi_p(B) = 1 - \sum_{i=1}^p \phi_i B^i$ representa el operador autorregresivo ordinario de orden p .
- $\theta_q(B) = 1 + \sum_{j=1}^q \theta_j B^j$ es el operador de media móvil ordinario de orden q .
- $\Phi_P(B^{24})$ y $\Theta_Q(B^{24})$ son los operadores estacionales de orden P y Q respectivamente, ajustados al periodo diurno $s = 24$.
- $(1 - B)^d$ y $(1 - B^{24})^D$ representan las diferencias ordinarias (d) y estacionales (D).
- $F_{m,t}$ corresponde a la serie del m -ésimo factor latente continuo obtenido del AFE individual de la estación, con su respectivo coeficiente de regresión γ_m .
- $\epsilon_t \sim \mathcal{N}(0, \sigma^2)$ es el término de error de ruido blanco.

Selección de Ordenes y Evaluación por Estación

Con el objetivo de optimizar el tiempo computacional y evitar la exploración exhaustiva del ajuste del modelo SARIMAX en las 15 estaciones de la red, la estrategia de selección se basó en el análisis de agregación diaria de los datos. A partir de este filtrado a nivel diario, se identificaron los patrones extremos y se ejecutó la búsqueda de parámetros sobre las tres estaciones pivote seleccionadas, acotando el espacio de iteración del modelo sin comprometer la captura de la dinámica ambiental.

La identificación de los órdenes $(p, d, q) \times (P, D, Q)_{24}$ se fundamentó en la inspección de las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) sobre las series diferenciadas, optimizada posteriormente mediante la minimización del Criterio de Información de Akaike (AIC) mediante un gridsearch de los valores de los hiperparámetros $(p, d, q) \times (P, D, Q)_{24}$.

Se evaluó el desempeño predictivo en una ventana de validación fuera de muestra (*out-of-sample*) con un horizonte operativo de $h = 7$ horas, correspondiente al rango útil para la toma de decisiones preventivas en el SIMA.

Estación	Modelo SARIMAX	RMSE	MAE	R^2
NO2	$(2, 0, 2) \times (0, 1, 1)_{24}$	11.42	8.15	0.81
SE3	$(2, 0, 2) \times (0, 1, 1)_{24}$	14.88	10.32	0.76
NE3	$(2, 1, 0) \times (0, 1, 1)_{24}$	12.05	8.74	0.79

Tabla 1: Resultados de los modelos SARIMAX por estación.

La comparativa gráfica de las métricas de error para las tres estaciones se presenta en el Anexo (Figura 17).

Desempeño Ajustado por Microclima

1. Estación NO2 (García - Poniente)

El modelo capturó con alta precisión el ciclo de resuspensión de material particulado. La inclusión del Factor_1_Photochemical y el Factor_2_Temperature demostró significancia estadística ($p < 0.01$), aportando una reducción del 14 % en el RMSE en comparación con un modelo ARIMA puramente univariado. El coeficiente $R^2 = 0.81$ refleja un ajuste sólido ante cambios abruptos en la dirección del viento.




Figura 4: Relación entre la velocidad del viento (WSR) y PM_{10} con tendencia no lineal (LOWESS) para el triplete. La cola ascendente refleja el fenómeno de resuspensión de polvo inorgánico característico de NO2 (García).




Figura 5: Pronóstico fuera de muestra (horizonte de 7 horas) vs valores reales de PM_{10} en la estación NO2 (García).

2. Estación SE3 (Cadereyta - Suroriente)

Esta estación presentó la mayor varianza residual debido a las emisiones intermitentes de origen industrial. Sin embargo, la inclusión del Factor_2_Combustion (dominado por NO_2 , NO y $PM_{2.5}$) permitió anticipar los picos nocturnos generados por eventos de inversión térmica sobre la cuenca del río San Juan, manteniendo un error medio absoluto (MAE) de $10.32 \mu\text{g}/\text{m}^3$.

El pronóstico horario fuera de muestra y su diagnóstico de residuos se presentan en el Anexo (Figura 7 y Figura 9).

3. Estación NE3 (Pesquería - Nororiente)

El comportamiento de PM_{10} en Pesquería estuvo estrechamente acoplado al Factor_1_Moisture. La alta carga de humedad relativa en este factor permitió modelar el efecto amortiguador de la condensación matutina sobre el polvo en suspensión, alcanzando un $R^2 = 0.79$ en la ventana de pronóstico a 7 horas.

El pronóstico horario fuera de muestra y su diagnóstico de residuos se presentan en el Anexo (Figura 8 y Figura 10).

Diagnóstico y Validación de Residuos

Para validar la solidez estadística de los modelos estimadores, los residuos $\hat{\epsilon}_t$ fueron sometidos a pruebas rigurosas de independencia y normalidad:

- **Prueba de Ljung-Box (Ausencia de Autocorrelación):** Se evaluó la hipótesis nula de independencia de residuos hasta el retardo $k = 48$. Para los tres modelos, los p-valores superaron el umbral de significancia ($p > 0.05$), confirmando que la estructura autorregresiva y estacional ($s = 24$) absorbió la dependencia temporal de las series.
- **Homocedasticidad y Distribución del Error:** Aunque la transformación Yeo-Johnson corrigió la asimetría severa, los residuos mantuvieron colas ligeramente pesadas (leptocurtosis) explicadas por eventos atípicos extremos no planificados. No obstante, la varianza residual permanece estable a lo largo del horizonte predictivo.
- **Significancia de las Exógenas (X_t):** Los p-valores asociados a los coeficientes factoriales (γ_m) resultaron significativos al 99 % de confianza en todas las estaciones, validando la hipótesis de que la integración de la meteorología y contaminantes precursores —libres de colinealidad— mejora el pronóstico frente a series de tiempo aisladas. Únicamente la estación en García resultó apta para predecir por sí misma una gran cantidad de varianza, demostrando autocorrelación dentro del modelo.
- **Descripción de gráficas:** El modelo de García resulta ser el más apropiado, ya que demuestra cierta homocedasticidad notable oscilando en el cero, lo que confirma el poco sesgo que tiene este modelo. En el modelo de cadereyta (Figura 9), se nota el sesgo con valores atípicos de PM_{10} en la cola izquierda. Los valores de los residuos indican valores que sobrepasan las 5 y hasta 8 desviaciones estándares a principios de los meses expuestos, posiblemente habiendo un desnivel en esa parte del año. Más allá de ello, la estación de Cadereyta demuestra un comportamiento acertado. Por otro lado, esta la estación de pesquería (Figura 10), comportándose con un ruido de residuos




Figura 6: Diagnóstico de los residuos del modelo SARIMAX de la estación NO2 (García): serie temporal, histograma vs normal, Q-Q, ACF, PACF y residuos vs valores ajustados.

más equilibrados, pero más dispersos. Aún así, la estación de pesquería demuestra la mejor asemejanza a la distribución normal. El resultado que comprueba la presencia de cierta falta de adaptación viable de los hiperparámetros es el de la gráfica ACF que demuestra que los rezagos no lograron incorporar o adaptar adecuadamente a los componentes seleccionados para el modelo.

Conclusiones y Recomendaciones

El marco metodológico integrado en este estudio demuestra la viabilidad de implementar un Sistema de Alerta Temprana para la Zona Metropolitana de Monterrey con sustento estadístico riguroso e interpretable:

1. **Selección Espacial Optimizada:** La Distancia de Mahalanobis ($D_M = 19.97$) probó ser superior a los enfoques de agrupamiento tradicionales (k -means), preservando la firma microclimática e industrial de las estaciones críticas sin distorsionar los picos atípicos.
2. **Eliminación Efectiva de Colinealidad:** El Análisis Factorial individualizado redujo la alta correlación entre predictores atmosféricos, generando variables sintéticas ortogonales adaptadas a la realidad de cada estación. Esto permitió reducir la complejidad del modelo SARIMAX, reduciendo el número de coeficientes de regresión y asimismo la cantidad de parámetros a ajustar.
3. **Capacidad Predictiva Operativa:** La arquitectura SARIMAX con covariables factoriales alcanzó un coeficiente de determinación $R^2 \geq 0.76$ en un horizonte

de pronóstico a 7 horas, con errores medios dentro de rangos aceptables para la gestión ambiental pública.

Dados los resultados obtenidos y las predicciones con comportamientos marcadamente disímiles entre sí —los cuales justifican la selección preliminar de estaciones con mayor distancia de Mahalanobis—, es posible inferir que las demás estaciones no tratadas en este reporte presentan comportamientos combinados de estos tres nodos representativos. Bajo esta premisa, la predicción de PM_{10} en toda la red SIMA podría quedar acotada por estos tres modelos pivote, favoreciendo la generalización del fenómeno y optimizando la eficiencia computacional de los pronósticos. Conceptualmente, esto permitiría estructurar un perfil de estimación espacial donde el comportamiento de cualquier estación n diferente de las tres analizadas se modele como una combinación lineal de las series de tiempo centinela:

$$S_n(t) = \alpha \cdot NO_2(t) + \beta \cdot SE_3(t) + \gamma \cdot NE_3(t)$$

(donde $\alpha, \beta, \gamma \geq 0$ representan los pesos de influencia espacial u orográfica).

Sin embargo, dado el alcance de este trabajo, el desarrollo y validación de esta formulación se deja planteado como una línea de investigación posterior para profundizar en la dinámica atmosférica de la cuenca.

Recomendaciones para el SIMA

- **Aviso Anticipado a 7 Horas:** Utilizar la ventana de predicción del modelo para emitir alertas de precontingencia con al menos 6 horas de antelación, permitiendo coordinar la restricción del tráfico de carga pesada en la zona Poniente (García) y regular procesos industriales intermitentes en el sector Suroriente (Cadereyta).
- **Hiperparametrización correcta:** Manejar una mejor búsqueda de hiperparámetros apropiados que puedan explicar mejor la variabilidad de PM_{10}

Líneas de Investigación Futura

- **Modelos Híbridos de Aprendizaje Profundo:** Integrar arquitecturas no lineales (e.g., LSTM o Graph Neural Networks) combinadas con los factores latentes extraídos por AFE para evaluar mejoras en la captura de picos atípicos de corta duración.
- **Variables Espaciotemporales de Capa Límite:** Incorporar mediciones de la altura de la capa de mezcla y perfiles térmicos verticales obtenidos vía perfiles de viento o datos satelitales como covariables exógenas adicionales.

Referencias

- Cerón-Bretón, R. M., Cerón-Bretón, J. G., Espinosa-Fuentes, M. d. I. L., Kahl, J. D. W., Espinosa-Guzmán, A. A., García-Martínez, R., Guarnaccia, C., Lara-Severino, R. d. C., Ramírez-Lara, E., & Francavilla, A. B. (2021). Short-Term Associations between Morbidity and Air Pollution in Metropolitan Area of Monterrey, Mexico. *Atmosphere*, 12(10), 1352. <https://doi.org/10.3390/atmos12101352>
- González-Santiago, O., Badillo-Castañeda, C. T., Kahl, J. D. W., Ramírez-Lara, E., & Balderas-Rentería, I. (2011). Temporal analysis of PM_{10} in Metropolitan Monterrey, Mexico. *Journal of the Air & Waste Management Association*, 61(5), 573-579. <https://doi.org/10.3155/1047-3289.61.5.573>
- Ramírez-Gómez, G. A., Ramírez-Guzmán, M. E., Romero-Padilla, J. M., Macedo-Cruz, A., Ortiz-Solorio, C. A., Rendón-Sánchez, G., Gutiérrez-Castorena, E. V., & Encinia-Urbe, V. V. (2025). Modeling of the PM_{10} pollutant in Monterrey, Nuevo León, Mexico, with ARIMA, transfer functions and GARCH models. *Atmósfera*, 39, 553-575. <https://doi.org/10.20937/ATM.53488>
- Secretaría de Salud. (2021, octubre). NORMA Oficial Mexicana NOM-025-SSA1-2021, Salud ambiental. Criterios para evaluar la calidad del aire ambiente, con respecto a las partículas suspendidas (PM_{10} y $PM_{2.5}$). Valores límite permisibles para su concentración en el aire ambiente y directrices para su evaluación (inf. téc.). Diario Oficial de la Federación. Ciudad de México, México. https://dof.gob.mx/nota_detalle.php?codigo=5633855

% Pasa a 1 columna completa para que los Anexos respiren y no colapsen

Anexos

Pronósticos Fuera de Muestra (SE3 y NE3)

Tabla 2: Cargas factoriales rotadas (Varimax), unicidad y varianza explicada por estación centinela

Estación	Variable	F1	F2	F3	Unicidad (u^2)
NO2 (García)	O3	0.787*	-0.222	-	0.332
	PRS	-0.043	0.721*	-	0.479
	RH	-0.624*	0.233	-	0.556
	TOUT	0.386	-0.770*	-	0.258
	WSR	0.573*	-0.215	-	0.625
SE3 (Cadereyta)	CO	0.151	0.433*	-0.030	0.789
	NO	0.153	0.692*	-0.159	0.472
	NO2	0.224	0.751*	-0.190	0.350
	O3	-0.277	-0.203	0.765*	0.297
	PM2.5	-0.157	0.631*	0.179	0.545
	PRS	0.617*	-0.031	0.045	0.616
	SO2	-0.066	0.107	0.421*	0.807
	SR	-0.230	0.007	0.675*	0.492
	TOUT	-0.924*	-0.136	0.272	0.054
	WSR	-0.248	-0.331	0.182	0.796
	WDR	0.273	0.301	-0.106	0.824
	NO	0.200	0.490*	0.076	0.714
NE3 (Pesquería)	NO2	0.074	0.859*	0.223	0.206
	O3	-0.644*	-0.369	-0.188	0.414
	PRS	0.062	-0.025	0.649*	0.574
	RH	0.995*	0.014	0.197	0.000
	TOUT	-0.344	-0.268	-0.882*	0.031
	WSR	-0.410*	-0.296	-0.221	0.696
	WDR	0.027	0.369*	0.334	0.752




Figura 7: Pronóstico horario fuera de muestra (horizonte de 7 horas) vs valores reales de PM_{10} en SE3 (Cadereyta).




Figura 8: Pronóstico horario fuera de muestra (horizonte de 7 horas) vs valores reales de PM_{10} en NE3 (Pesquería).

Diagnóstico de Residuos del Modelo (SE3 y NE3)




Figura 9: Residuos del modelo SARIMAX de la estación SE3 (Cadereyta): serie temporal, histograma vs normal, Q-Q, ACF, PACF y residuos vs valores ajustados.




Figura 10: Residuos del modelo SARIMAX de la estación NE3 (Pesquería): serie temporal, histograma vs normal, Q-Q, ACF, PACF y residuos vs valores ajustados.

Análisis Factorial Exploratorio por Estación





Figura 11: Scree plot de la estación NO2 (García) con el criterio de Kaiser ($\lambda = 1$) y el número de factores retenidos. Figura 12: Scree plot de la estación SE3 (Cadereyta) con el criterio de Kaiser ($\lambda = 1$) y el número de factores retenidos.




Figura 13: Scree plot de la estación NE3 (Pesquería) con el criterio de Kaiser ($\lambda = 1$) y el número de factores retenidos.




Figura 14: Diagrama de cargas factoriales de la estación NO2 (García). El grosor de la flecha es proporcional a la carga y el color rojo indica carga negativa.




Figura 15: Diagrama de cargas factoriales de la estación SE3 (Cadereyta). El grosor de la flecha es proporcional a la carga y el color rojo indica carga negativa.




Figura 16: Diagrama de cargas factoriales de la estación NE3 (Pesquería). El grosor de la flecha es proporcional a la carga y el color rojo indica carga negativa.

Métricas Comparativas de los Modelos




Figura 17: Comparativa de métricas de error (MAE, RMSE y MAPE) obtenidas en la ventana de validación fuera de muestra (7 horas) para las tres estaciones.

Repositorio del Proyecto

El código fuente de los scripts de limpieza de datos, análisis exploratorio, selección por Mahalanobis, análisis factorial y modelación SARIMAX, así como las figuras y recursos del proyecto, está disponible en el repositorio público:

https://github.com/INFOAOAA/SIMA_Proyecto