

Comprensión de los datos y descripción de variables



Etapa 2

Conociendo los datos

ANGEL RUBEN GALINDO ALVAREZ & A00228356

JORGE RAUL MARTINEZ RAMIREZ & A01286802

ROBERTO PEREZ CASTILLO & A01286834

ALEJANDRO TORRES & A00840943

EQUIPO 6

MA2003B Análisis Multivariado | Blanca Rosa Ruiz Hernández

Raúl Gómez Muñoz

Table of contents

Objetivo del análisis y justificación del alcance	2
Pregunta de investigación:	2
Objetivo general:	2
Técnicas estadísticas	2
Por qué es clave la estación de monitoreo	3
Diccionario de Variables	3
Características Estadísticas	4
Exploración Visual de los Datos	5
Verificación de la Calidad de los Datos	5
Selección de variables	6
ANOVA	6
Random Forest	6
Resumen, Próximos Pasos y Preguntas Emergentes	7
6. Anexos y Repositorio	7
Declaratoria de uso de IA durante el desarrollo del trabajo	7

Objetivo del análisis y justificación del alcance

Pregunta de investigación:

¿De qué manera influyen las variables del clima en los picos de contaminación (PM_{10} , $PM_{2.5}$ y O_3) dentro de las distintas estaciones de monitoreo del Área Metropolitana de Monterrey entre 2020 y 2025?

Objetivo general:

Crear y validar modelos predictivos utilizando datos históricos de 2020 a 2025 para estimar las concentraciones de PM_{10} , $PM_{2.5}$ y O_3 en conjunto. La idea es identificar qué factores climáticos detonan las contingencias en cada zona y darle al SIMA una herramienta práctica para poder anticiparlas.

Decidimos mantener el análisis de los contaminantes integrado porque, aunque las partículas (PM_{10} y $PM_{2.5}$) comparten fuentes de emisión y se comportan de forma muy similar, el ozono (O_3) funciona diferente al depender mucho más del calor y la radiación solar. Juntar ambos comportamientos en un solo sistema resulta mucho más útil para tomar decisiones públicas que si hiciéramos modelos separados.

Técnicas estadísticas

Para cumplir con este objetivo y asegurarnos de que el SIMA pueda interpretar los resultados fácilmente para convertirlos en acciones, utilizaremos las siguientes herramientas:

- Estadística descriptiva y detección de valores atípicos: Usaremos diagramas de caja para entender cuáles son los niveles “normales” de contaminación y aislar los días que realmente representan una contingencia en cada estación.
- Análisis de correlación: Nos ayudará a ver cómo se relacionan los contaminantes entre sí (por ejemplo, la fuerte conexión entre PM_{10} y $PM_{2.5}$) y cómo reaccionan a los cambios del clima, trabajando siempre con los datos en sus unidades originales.
- Random Forest (Árboles de decisión): Elegimos este algoritmo porque hace pronósticos basados en reglas lógicas. Limitaremos qué tan complejos se vuelven estos árboles para que no se conviertan en una “caja negra” y siempre podamos explicar de dónde salió la predicción.

Para poder predecir la contaminación, trabajaremos con el archivo `SIMA_Diario_Imputado.csv`, el cual consolida las lecturas por día.

Este archivo lo armamos uniendo seis documentos de Excel que contenían el historial por hora (2020-2025) de las 15 estaciones de monitoreo de Monterrey. Para hacer la información más manejable, sacamos los promedios diarios, pero le pusimos una regla estricta: solo validamos los días que tuvieran al menos 18 horas de mediciones reales. Los huecos de información que quedaron por cualquier motivo los rellenamos respetando el orden cronológico exacto de los días. Así nos

aseguramos de tener una base continua sin hacer “trampa” (mezclando información del futuro en el pasado) antes de empezar a modelar. Cabe recalcar que también respetamos el comportamiento de cada estación, es decir, no imputamos los datos de una estación el comportamiento de otra.

Por qué es clave la estación de monitoreo

La variable de la estación es una de las piezas más importantes del proyecto. Como Monterrey está rodeado de montañas, se generan distintos microclimas y “trampas” donde el aire se estanca. Esto significa que la contaminación por PM10 en la zona suroeste no se comporta para nada igual que en la zona sur. Si ignoramos de qué estación viene cada dato, terminaríamos revolviendo todo y el modelo no entendería cómo se mueve y dispersa realmente la contaminación en la ciudad.

Diccionario de Variables

Variable	Descripción	Tipo de Dato	Rango / Valores Posibles	Valores Nulos
Fecha	Fecha cronológica de la lectura	Cualitativa (Ordinal)	2020-01-01 a 2025-12-31	0
Estacion	Código de la estación de monitoreo	Cualitativa (Nominal)	15 valores (ej. CE, NE, SO, SUR)	0
PM10	Partículas menores a 10 micrómetros (Objetivo)	Cuantitativa (Continua)	0– > 500 $\mu\text{g}/\text{m}^3$	0
PM2.5	Partículas menores a 2.5 micrómetros	Cuantitativa (Continua)	0– > 300 $\mu\text{g}/\text{m}^3$	0
TOUT	Temperatura ambiente externa	Cuantitativa (Continua)	–5.0 a 45.0 °C	0
RH	Humedad relativa	Cuantitativa (Continua)	0 a 100 %	0
WSR	Velocidad del viento	Cuantitativa (Continua)	0 a 50 km/h	0
PRS	Presión atmosférica	Cuantitativa (Continua)	600 a 800 mmHg	0
O3	Ozono	Cuantitativa (Continua)	0 a 200 ppb	0
NO2	Dióxido de nitrógeno	Cuantitativa (Continua)	0 a 100 ppb	0
CO	Monóxido de carbono	Cuantitativa (Continua)	0 a 10 ppm	0

Características Estadísticas

Dimensión del dataset: 31449 registros y 18 columnas.

Estadísticas de Variables Cuantitativas:


	Media	Mediana	Desv.Est	Varianza	Min	Max
Horas_Registradas	23.99	24	0.08	0.01	22	24
CO	1.32	1.15	0.85	0.73	0.05	9.21
NO	15.32	7.1	29.27	856.96	0.5	427.29
NO2	14.68	12.72	8.88	78.89	0.06	95.18
NOX	29.45	20.28	32.5	1056.52	0.5	457.95
O3	26.78	26.5	9.42	88.8	1.5	77.75
PM10	57.46	52.29	27.85	775.62	5.76	301.54
PM2.5	20.27	18.97	10.18	103.54	2	191.39
PRS	715.24	714.26	9.27	85.84	681.81	747.67
RH	55	57.25	17.48	305.52	1.48	99.72
SO2	4.96	4.15	3.13	9.81	0.59	61.78
SR	0.15	0.15	0.23	0.06	0	25.34
TOUT	22.79	24.51	8.01	64.23	-57.79	36.78
WDR	140.98	134.21	62.15	3863.11	1.45	357.14
WSR	8.31	7.9	4.73	22.42	0.1	158.86
RAINF	0.71	0	32.09	1029.46	0	4897.1

Tabla de Frecuencia (Estación):

Estacion	Frecuencia
CE	2192
NE	2192
NE2	2192
NO	2192
NO2	2192
NTE	2192
NTE2	2192
SE	2192
SE2	2192
SE3	2192
SO	2192
SO2	2192
SUR	2192
NE3	1826
NO3	1127

Exploración Visual de los Datos

A continuación, visualizamos el comportamiento de las variables cuantitativas (distribución, asimetría, dispersión y correlación multivariada) y cualitativas, utilizando la base de datos validada.



Verificación de la Calidad de los Datos

- **Valores Nulos:** 0 detectados.
- **Registros Duplicados:** 0 detectados.
- **Valores Negativos Inconsistentes:** 0 detectados.
- **Formato de Fechas Correcto:** Sí

Conclusión de Calidad: El dataset cumple con los criterios de integridad necesarios para la siguiente fase de la metodología CRISP-DM.

Selección de variables

En esta etapa, nos centramos en seleccionar las variables que nos resulten más útiles para predecir la contaminación. Para ello, utilizaremos algunas técnicas estadísticas para evaluar la calidad de las variables y determinar cuáles son las más importantes para el modelo.

ANOVA

Primero utilizaremos la técnica de ANOVA (Analysis of Variance) para saber si entre las estaciones hay diferencias significativas en la distribución de las variables, como se puede ver en la siguiente tabla. Fast y Zhong, [1998](#)

	Variable	p_value	Homoscedastic	Test	ANOVA_p	Significant
0	CO	0.0000	False	Welch's ANOVA	0.00000	True
1	NO	0.0000	False	Welch's ANOVA	0.00000	True
...	...	...	...	...	...	...
14	Mes	0.0339	False	Welch's ANOVA	0.00002	True
15	Hora	1.0000	True	Standard ANOVA	1.00000	False

Random Forest

Recomendaciones de regresores por estación mediante Random Forest:

Station	Samples_Used	Top_1_Regressor	Top_2_Regressor	Top_3_Regressor	Top_4_Regressor	Top_5_Regressor
CE	2192	NO2	SO2	CO	SR	
NE	2192	NOX	RH	SO2	PRS	
NE2	2192	NO2	RH	CO	PRS	
NE3	1826	RH	NO2	NOX	PRS	
NO	2192	SO2	NO	RH	WDR	
NO2	2192	RH	CO	TOUT	NO2	
NO3	1127	SR	RH	NO2	SO2	
NTE	2192	NOX	NO	RH	CO	
NTE2	2192	NO	RH	CO	PRS	
SE	2192	RH	NO2	PRS	CO	
SE2	2192	NO2	CO	RH	NOX	
SE3	2192	NOX	RH	NO2	CO	
SO	2192	RH	NOX	NO	PRS	
SO2	2192	PRS	NO2	CO	RH	
SUR	2192	RH	PRS	NO	CO	

Cada estación tiene su propio conjunto de variables que más influyen en la predicción de PM10. Por ejemplo, para la estación "CE", los factores como el NO₂ y SO₂ son cruciales, mientras que para "SUR", la humedad relativa y la presión atmosférica son más importantes. Genuer et al., [2010](#)

Resumen, Próximos Pasos y Preguntas Emergentes

Resumen de logros hasta ahora: Durante esta segunda etapa de la metodología CRISP-DM, hemos comprendido a fondo la estructura y calidad de los datos de la red SIMA. Se confirmó la limpieza absoluta del dataset (cero nulos tras la imputación temporal y cero valores negativos) y se generó un perfil estadístico claro. Descubrimos que el PM_{10} tiene una distribución asimétrica positiva y que sus valores atípicos representan contingencias ambientales reales, no errores del sensor. Asimismo, se comprobó una correlación multivariada útil donde factores climáticos (Humedad, Viento) actúan como mitigadores del contaminante.

Qué falta por hacer: El siguiente paso natural es adentrarnos en la fase de Modelado. Específicamente falta: 1. **Ingeniería de Características:** Crear variables de rezago histórico (*lags*) y promedios móviles semanales para capturar la inercia de la contaminación. 2. **Partición Temporal:** Dividir el dataset cronológicamente (Entrenamiento: 2020-2024, Validación: 2025). 3. **Entrenamiento y Evaluación:** Ajustar el modelo de Machine Learning y proyectar los 365 días del año 2026.

Preguntas que han surgido durante la exploración:

- Al observar la marcada diferencia espacial en los boxplots, ¿será más preciso entrenar un único modelo global que tome la estación como variable categórica, o construir 15 sub-modelos independientes (uno para cada estación)?
- Dado que los *outliers* de la asimetría derecha son críticos (días de contingencia), ¿qué función de pérdida (*loss function*) deberíamos usar en el algoritmo para no subestimar estos picos peligrosos para la salud?

6. Anexos y Repositorio

-
- **Liga al Repositorio de Trabajo:**
 - **GitHub:** https://github.com/INFOAOAA/SIMA_Proyecto.git.

Declaratoria de uso de IA durante el desarrollo del trabajo

Opción B. Se utilizó IA de la siguiente forma:

- **Herramienta:** Gemini (Google).
- **Uso realizado:** Se utilizó como asistente de programación y estructuración. La IA ayudó a redactar el código en Python (con enfoque en pandas, seaborn y matplotlib) bajo el formato de Quarto Document (.qmd). Asimismo, asistió en la estructuración lógica del reporte metodológico CRISP-DM (Etapa 2) y en la sintaxis para el cálculo de estadísticas descriptivas.
- **Secciones donde se utilizó:** En el planteamiento de técnicas estadísticas, generación de tablas de frecuencias y código de visualización.
- **Validación realizada por los estudiantes:** Se verificó que el código Python procesara correctamente el archivo CSV del proyecto, revisando visualmente los gráficos generados y cotejando que los estadísticos descriptivos (media, nulos, rangos) coincidieran con el conocimiento empírico de la base de datos de calidad del aire.

Confirmando que revisé, verifiqué y asumo la total responsabilidad del contenido final entregado

en esta actividad.

Referencias

- Fast, J. D., & Zhong, S. (1998). Meteorological factors associated with inhomogeneous ozone concentrations within the Mexico City basin. *Journal of Applied Meteorology and Climatology*, 37(11), 1496-1513. <https://doi.org/10.1029/98JD01725>
- Genuer, R., Poggi, J.-M., & Tuleau-Malot, C. (2010). Variable selection using random forests. *Pattern Recognition Letters*, 31(14), 2225-2236. <https://doi.org/10.1016/j.patrec.2010.03.014>