



Etapa 3

Adecuación y/o validación del Modelo

ANGEL RUBEN GALINDO ALVAREZ & A00228356
JORGE RAUL MARTINEZ RAMIREZ & A01286802
ROBERTO PEREZ CASTILLO & A01286834
ALEJANDRO TORRES & A00840943
EQUIPO 6

MA2003B Análisis Multivariado | Blanca Rosa Ruiz Hernández
Raúl Gómez Muñoz

Table of contents

Objetivo del Análisis y Evolución del Alcance

Pregunta de Investigación	1
Objetivo General	1
Cambios y Justificación del Alcance	1

Técnicas Estadísticas y Flujo Metodológico

Agregación Normativa y Filtros	2
Selección por Distancia de Mahalanobis	2

Resultados del Análisis Exploratorio

Modelado Predictivo y Técnicas Multivariadas

Análisis Factorial	2
Modelo SARIMAX y Validación de Errores	2
Importancia de Variables Exógenas	2
Validación de Supuestos Matemáticos	3

Conclusiones Parciales y Sigüientes Pasos

Enlace al Repositorio de Código:	3
----------------------------------	---

Declaratoria de uso de IA:

Anexos

Tabla A.1: Estadísticos Descriptivos de las Variables Continuas (2020–2025)	4
Información de la Calidad y Estructura de los Datos	4
Verificación de Continuidad Temporal	4
Estado de Valores Nulos y Tipos de Dato	5
Alertas de Coherencia	5
Selección de Estaciones Representativas	5
Figuras y Visualizaciones	6
Análisis Factorial	6

Objetivo del Análisis y Evolución del Alcance

1 Pregunta de Investigación

1 ¿De qué manera influyen las condiciones meteorológicas y los gases precursores en la variabilidad de las concentraciones diarias de material particulado (PM_{10}) en la Zona Metropolitana de Monterrey, y cómo puede optimizarse la selección de estaciones de monitoreo mediante distancia multivariada para construir modelos autorregresivos capaces de predecir contingencias ambientales en el corto plazo?

2 Objetivo General

2 Desarrollar y validar un marco de modelado predictivo multivariado para pronosticar concentraciones diarias de PM_{10} en tres estaciones pivote representativas de la Zona Metropolitana de Monterrey (SE3, NO2, NE3). Se utiliza la distancia de Mahalanobis para la selección de estaciones y el modelo estacional SARIMAX con variables exógenas para proveer al Sistema de Monitoreo Ambiental (SIMA) una herramienta funcional de alerta temprana.

3 Cambios y Justificación del Alcance

4 El diseño del proyecto se ajustó para reflejar la dinámica real de los datos del SIMA. Inicialmente, la información horaria presentaba huecos por fallas de sensores y volatilidad extrema por ráfagas de corta duración que distorsionaban la tendencia general de la calidad del aire. Para estabilizar la señal, se transicionó a promedios diarios. En apego a la norma NOM-025-SSA1, solo se validaron días con al menos 18 horas de registro ($\geq 75\%$ de disponibilidad). Las ventanas faltantes menores a tres horas se imputaron mediante interpolación lineal por estación, garantizando la continuidad sin mezclar comportamientos entre estaciones.

El cambio estructural más significativo fue el reemplazo del agrupamiento por k -means en favor de la Distancia de Mahalanobis. Los métodos de clustering tradicionales promedian el comportamiento de las estaciones, por lo cual los modelos tenían dificultades en encontrar los clusters ya que cada estación se comporta de manera significativamente diferente. La Distancia de Mahalanobis resolvió esto al evaluar la matriz de covarianza de los datos, consiguiendo el triplete de estaciones que exhibe los comportamientos más extremos y contrastantes, sin forzar promedios artificiales. Finalmente, el horizonte predictivo se ajustó de un año a una ventana de corto plazo. La meteorología pierde predictibilidad después de dos semanas; proyectar a 365 días acumula mucho error y se vuelve inútil para la gestión de contingencias.

Técnicas Estadísticas y Flujo Metodológico

Agregación Normativa y Filtros

Se depuró la base de datos eliminando anomalías registradas por los sensores (temperaturas de -57°C y vientos sobre 158 km/h), acotando los valores a límites realistas (-5°C a 45°C y máximo 80 km/h). Las correcciones se aplicaron mediante arrastre del último valor válido (forward fill) por estación Table 3.

Selección por Distancia de Mahalanobis

Para aislar las estaciones más distantes, la distancia entre dos estaciones i y j se definió como:

$$D_M(\mathbf{u}_i, \mathbf{u}_j) = \sqrt{(\mathbf{u}_i - \mathbf{u}_j)^T S_{\text{pooled}}^{-1} (\mathbf{u}_i - \mathbf{u}_j)}$$

Donde $\mathbf{u}_i$ es el vector de medias de las variables en la estación i , y S_{pooled}^{-1} es la pseudo-inversa de la matriz de covarianza agrupada. Se seleccionó el trío que maximiza la separación espacial Table 4:

Maximizar $\mathcal{D} = D_M(\mathbf{u}_1, \mathbf{u}_2) + D_M(\mathbf{u}_1, \mathbf{u}_3) + D_M(\mathbf{u}_2, \mathbf{u}_3)$

Resultados del Análisis Exploratorio

El procesamiento confirmó la heterogeneidad geográfica de la metrópoli. La selección de Mahalanobis arrojó una separación combinada de 19.97, aislando a SE3 (Cadereyta), NO2 (García) y NE3 (Pesquería).

El análisis visual confirma los mecanismos físicos de estas tres zonas:

- Efecto de Inversión Térmica: La Figure 1 demuestra un patrón en forma de "U". Durante los meses de invierno (noviembre a marzo), el enfriamiento del suelo impide la mezcla vertical del aire, disparando la concentración de PM_{10} con picos frecuentes por encima de los $150\text{ }\mu\text{g}/\text{m}^3$. En contraste, la inestabilidad atmosférica del verano facilita la ventilación, comprimiendo la dispersión de los datos.
- Agentes de Lavado Atmosférico: La Figure 2 corrige la percepción sobre la temperatura. La correlación del PM_{10} con la temperatura absoluta ($TOUT$) es nula (-0.03). El verdadero mecanismo de limpieza es la Humedad Relativa (RH , $r = -0.41$), cuyo efecto probablemente aglomera las partículas forzando su caída por gravedad.

- Dualidad del Viento: La Figure 3 ilustra cómo el viento funciona como vector de limpieza a velocidades moderadas (reduciendo la concentración base), pero desencadena eventos de resuspensión. Las ráfagas extremas elevan las concentraciones anómalas, particularmente visibles en la dispersión superior de la estación NO2.

Modelado Predictivo y Técnicas Multivariadas

Análisis Factorial

Para resolver los problemas de multicolinealidad entre los distintos contaminantes y las variables meteorológicas, se aplicó un Análisis Factorial. Esta técnica de interdependencia redujo la dimensionalidad del conjunto original extrayendo tres variables latentes principales: Factor_Combustion, Factor_Photochemical y Factor_Moisture. La creación de estos factores ortogonales permitió capturar la varianza combinada del sistema atmosférico en índices simplificados, garantizando el cumplimiento de los supuestos de no multicolinealidad requeridos para los modelos de regresión posteriores.

Modelo SARIMAX y Validación de Errores

Se implementaron modelos de series de tiempo SARIMAX utilizando los factores extraídos como variables exógenas para predecir el comportamiento del PM_{10} Table 5.

- El modelo para la estación NO2 es el más eficiente y apto para predicción operativa, presentando un error porcentual absoluto medio (MAPE) del 15.43 % y los errores absolutos más bajos de la red.
- Las estaciones SE3 y NO2 requirieron un nivel de diferenciación ($d = 1$) para estabilizar su media temporal, mientras que NE3 se modeló como un proceso puramente autorregresivo.
- Todos los modelos capturaron exitosamente un ciclo estacional de 7 días, reflejando la dinámica de la actividad vehicular e industrial de la zona metropolitana a lo largo de la semana.

Importancia de Variables Exógenas

Los factores extraídos (Factor_Combustion, Factor_Photochemical, Factor_Moisture) demostraron ser predictores estadísticamente significativos (valor $p < 0.05$, tendiendo a 0.000) en las tres estaciones. En la estación SE3 (Cadereyta), los coeficientes de regresión muestran que la humedad y la combustión

tienen el impacto más fuerte sobre la varianza del PM_{10} . En contraste, para la estación NE3 (Pesquería), el factor de combustión domina de forma aislada como la variable explicativa de mayor peso.

Validación de Supuestos Matemáticos

- **Estacionariedad:** Validada implícitamente mediante la diferenciación de primer orden en las ecuaciones de NO₂ y SE3, logrando que la media de la serie fuera constante en el tiempo.
- **Normalidad de Residuos:** La prueba de Jarque-Bera arrojó valores de curtosis superiores a 10 para SE3 y NO₂. Esto indica que los residuos no se distribuyen de forma normal (son fuertemente leptocúrticos), ya que el modelo lineal subestima los picos anómalos o extremos de contaminación.
- **Homocedasticidad:** La prueba de Ljung-Box sugiere la presencia de heterocedasticidad temporal; la varianza de los errores cambia, incrementándose drásticamente durante los episodios de muy alta concentración.

Conclusiones Parciales y Siguiendo Pasos

El uso combinado del Análisis Factorial y la Distancia de Mahalanobis permitió aislar eficientemente las dinámicas subyacentes de calidad del aire y seleccionar las tres estaciones con comportamientos más contrastantes (NO₂, SE3, NE3), eliminando la redundancia espacial en la red de monitoreo. La implementación de modelos SARIMAX validó que la meteorología, los factores de combustión y la periodicidad semanal son excelentes predictores base de la contaminación (alcanzando un destacable error del 15.43 % en la estación NO₂).

Sin embargo, el análisis de residuos indica que las ecuaciones lineales subestiman los episodios extremos de PM_{10} , evidenciado por la alta curtosis y la heterocedasticidad de los errores. Para la siguiente fase, el objetivo primario evolucionará para enfocarse en la optimización del modelado de estos eventos extremos. El camino a seguir consistirá en explorar transformaciones logarítmicas en la variable dependiente, o evaluar la integración de algoritmos no lineales (como XGBoost o redes neuronales) en un formato de ensamble para corregir los picos residuales y mejorar el MAPE en las estaciones SE3 y NE3.

Enlace al Repositorio de Código:

[Enlace al Repositorio de Código del Documento](#)

Declaratoria de uso de IA:

Opción B. Se utilizó IA especificando:

- Herramienta: Gemini.
- Uso realizado: Evaluación del borrador contra los requisitos de la rúbrica, estructuración del documento al formato QMD (Markdown), y apoyo en la síntesis y redacción de los resultados técnicos (Análisis Factorial, métricas de error de SARIMAX).
- Secciones donde se utilizó: “Modelado Predictivo y Técnicas Multivariadas”, “Conclusiones Parciales y Siguiendo Pasos”, y la configuración general del preámbulo QMD.
- Validación realizada por los estudiantes: Verificamos que todas las interpretaciones estadísticas y métricas correspondieran a las salidas generadas por nuestro código.
- Confirmación: Confirmamos que se revisó, verificó y que se asume la responsabilidad del contenido final entregado.

Anexos

Tabla A.1: Estadísticos Descriptivos de las Variables Continuas (2020–2025)

Variable	Descripción	Unidad	Media	Mediana	Desv. Est.	IQR	Mín	Máx
PM ₁₀	Partículas en suspensión < 10 μm	μg/m ³	62.45	54.10	38.20	42.15	2.10	380.00
PM _{2.5}	Partículas finas < 2.5 μm	μg/m ³	24.18	21.00	14.30	16.50	0.50	195.00
O ₃	Ozono	ppb	28.35	25.20	18.10	22.40	0.00	145.00
NO ₂	Dióxido de nitrógeno	ppb	15.80	13.90	9.40	11.20	0.00	85.00
SO ₂	Dióxido de azufre	ppb	7.62	4.80	8.15	6.90	0.00	92.00
TOUT	Temperatura ambiente	°C	22.40	23.10	6.85	9.50	-2.50	43.80
RH	Humedad relativa	%	58.20	60.10	19.40	28.30	8.00	99.00
WSR	Velocidad del viento	km/h	8.45	7.20	4.60	5.80	0.10	42.00

Información de la Calidad y Estructura de los Datos

En esta sección se detallan las características del conjunto de datos utilizado, incluyendo los registros, valores nulos y continuidad temporal.

Información General: - Total de registros: 31,449 - Total de columnas: 18 - Estaciones únicas: 15 - Memoria (MB): 4.4

Verificación de Continuidad Temporal

Table 1: Verificación de continuidad temporal por estación

Estación	Fecha Inicio	Fecha Fin	Días Esperados	Días Registrados	Días Faltantes	Continuo
CE	2020-01-01	2025-12-31	2192	2192	0	True
NE	2020-01-01	2025-12-31	2192	2192	0	True
NE2	2020-01-01	2025-12-31	2192	2192	0	True
NE3	2021-01-01	2025-12-31	1826	1826	0	True
NO	2020-01-01	2025-12-31	2192	2192	0	True
NO2	2020-01-01	2025-12-31	2192	2192	0	True
NO3	2022-12-01	2025-12-31	1127	1127	0	True
NTE	2020-01-01	2025-12-31	2192	2192	0	True
NTE2	2020-01-01	2025-12-31	2192	2192	0	True
SE	2020-01-01	2025-12-31	2192	2192	0	True

Estación	Fecha Inicio	Fecha Fin	Días Esperados	Días Registrados	Días Faltantes	Continuo
SE2	2020-01-01	2025-12-31	2192	2192	0	True
SE3	2020-01-01	2025-12-31	2192	2192	0	True
SO	2020-01-01	2025-12-31	2192	2192	0	True
SO2	2020-01-01	2025-12-31	2192	2192	0	True
SUR	2020-01-01	2025-12-31	2192	2192	0	True

Estado de Valores Nulos y Tipos de Dato

Table 2: Estado de valores nulos y tipos de dato de las variables registradas

Variable	Tipo de Dato	Valores Nulos	Porcentaje Nulos (%)
Fecha	datetime64[us]	0	0.0
Horas_Registradas	float64	0	0.0
CO, NO, NO2, NOX, O3	float64	0	0.0
PM10, PM2.5, PRS, RH	float64	0	0.0
SO2, SR, TOUT, WDR, WSR, RAINF	float64	0	0.0
Estacion	str	0	0.0

Alertas de Coherencia

Table 3: Alertas de coherencia física en los datos meteorológicos

Variable	Mínimo Detectado	Máximo Detectado	Valores Anómalos
TOUT	-57.794348	36.783889	247
WSR	0.104348	158.858333	7
PRS	681.805556	747.666667	31449

Selección de Estaciones Representativas

Basado en el análisis espacial, las 3 estaciones más representativas seleccionadas son **NE3**, **NO2** y **SE3**, con una Separación de Mahalanobis Combinada de **19.9786**.

Table 4: Matriz de Distancia de Mahalanobis por Pares

	CE	NE	NE2	NE3	NO	NO2	NO3	NTE	NTE2	SE	SE2	SE3	SO	SO2	SUR
CE	0.00	2.48	2.67	5.70	1.02	3.61	2.47	2.51	2.28	3.95	3.77	6.20	3.30	1.50	2.21
NE	2.48	0.00	2.61	3.58	2.33	5.70	3.87	3.05	2.60	1.66	2.05	4.01	5.47	1.85	3.33
NE2	2.67	2.61	0.00	5.02	2.20	4.74	3.55	3.39	2.97	3.30	3.36	5.40	4.47	2.06	2.69
NE3	5.70	3.58	5.02	0.00	5.37	8.74	6.99	5.34	5.65	2.39	2.70	2.01	8.55	5.07	5.96
NO	1.02	2.33	2.20	5.37	0.00	3.71	2.68	2.52	2.30	3.62	3.54	5.92	3.40	1.31	1.96
NO2	3.61	5.70	4.74	8.74	3.71	0.00	2.91	4.54	4.48	7.04	6.87	9.23	1.12	4.11	3.41
NO3	2.47	3.87	3.55	6.99	2.68	2.91	0.00	2.87	2.65	5.16	5.38	7.30	3.01	2.46	2.92
NTE	2.51	3.05	3.39	5.34	2.52	4.54	2.87	0.00	2.60	4.10	4.09	5.84	4.30	2.53	3.17
NTE2	2.28	2.60	2.97	5.65	2.30	4.48	2.65	2.60	0.00	4.03	4.19	6.04	4.15	2.04	2.99
SE	3.95	1.66	3.30	2.39	3.62	7.04	5.16	4.10	4.03	0.00	1.82	2.77	6.85	3.14	4.42
SE2	3.77	2.05	3.36	2.70	3.54	6.87	5.38	4.09	4.19	1.82	0.00	3.00	6.66	3.49	4.48

	CE	NE	NE2	NE3	NO	NO2	NO3	NTE	NTE2	SE	SE2	SE3	SO	SO2	SUR
SE3	6.20	4.01	5.40	2.01	5.92	9.23	7.30	5.84	6.04	2.77	3.00	0.00	9.06	5.58	6.63
SO	3.30	5.47	4.47	8.55	3.40	1.12	3.01	4.30	4.15	6.85	6.66	9.06	0.00	3.88	3.38
SO2	1.50	1.85	2.06	5.07	1.31	4.11	2.46	2.53	2.04	3.14	3.49	5.58	3.88	0.00	1.94
SUR	2.21	3.33	2.69	5.96	1.96	3.41	2.92	3.17	2.99	4.42	4.48	6.63	3.38	1.94	0.00

Figuras y Visualizaciones

Para un análisis visual del comportamiento de los contaminantes y su relación con las variables meteorológicas, se incluyen las siguientes figuras:




Figure 1: Distribución de PM10

Análisis Factorial

Table 5: factores extraídos como variables exógenas para predecir el comportamiento del PM_{10}

Estación	Modelo SARIMAX	Estacionalidad	MAE ($\mu\text{g}/\text{m}^3$)	RMSE ($\mu\text{g}/\text{m}^3$)	MAPE (%)
NO2	(1, 1, 2)	(1, 0, 1, 7)	7.279	8.653	15.43
SE3	(1, 1, 2)	(1, 0, 1, 7)	13.373	20.123	35.38
NE3	(1, 0, 0)	(1, 0, 0, 7)	10.666	12.651	40.39




Figure 2: Matriz de Correlación




Figure 3: Relación Velocidad del Viento (WSR) vs PM10