

Anexo B: Formulación y Matriz Extendida de Mahalanobis



Reporte de Análisis Multivariado

Monitoreo SIMA y Selección de Estaciones

ANGEL RUBEN GALINDO ALVAREZ & A00228356

JORGE RAUL MARTINEZ RAMIREZ & A01286802

ROBERTO PEREZ CASTILLO & A01286834

ALEJANDRO TORRES & A00840943

EQUIPO 6

MA2003B Análisis Multivariado | Blanca Rosa Ruiz Hernández
Raúl Gómez Muñoz

Table of contents

Objetivo del Análisis y Evolución del Alcance	1
Pregunta de Investigación	1
Objetivo General	1
Cambios y Justificación del Alcance	1
Técnicas Estadísticas y Flujo Metodológico	1
1. Agregación Normativa e Imputación Jerárquica	2
2. Diagnóstico de Homogeneidad Espacial	2
3. Selección por Distancia de Mahalanobis	2
4. Evaluación de Importancia de Variables con Random Forest	2
5. Estrategia de Modelado Predictivo Temporal	2
Resultados del Análisis de esta Etapa	2
1. Integridad y Perfil Estadístico Post-Procesamiento	2
2. Pruebas de Heterocedasticidad y Divergencia Espacial	2
3. Selección Espacial por Distancia de Mahalanobis	3
4. Importancia de Variables e Insumos Explicativos	3
Resumen, Conclusiones Parciales y Próximos Pasos	3
Resumen de Logros	3
Próximos Pasos y Ruta de Trabajo	3
Preguntas Emergentes de Investigación	4
Anexos	5
Anexo A: Descriptivos y Panel Visual Multivariado	5
Tabla A.1: Estadísticos Descriptivos de las Variables Continuas (2020–2025)	5

Objetivo del Análisis y Evolución del Alcance

Pregunta de Investigación

¿De qué manera influyen las variables meteorológicas y los gases precursores en la variabilidad de los picos de contaminación por partículas (PM₁₀) en la Zona Metropolitana de Monterrey (ZMM), y cómo se pueden seleccionar estaciones representativas para predecir contingencias a corto plazo (7 a 14 días)?

Objetivo General

Desarrollar una metodología estadística multivariada para seleccionar un subconjunto óptimo de estaciones pivote en la ZMM y construir modelos predictivos a corto plazo para la concentración diaria de PM₁₀, proporcionando al Sistema de Monitoreo Ambiental (SIMA) una herramienta operativa de alerta temprana.

Cambios y Justificación del Alcance

Respecto a la propuesta inicial del proyecto, el alcance fue reorientado a partir de la evaluación técnica y las restricciones físicas del problema:

- 1. Sustitución del *Clustering* por Distancia de Mahalanobis:** Se eliminó el agrupamiento no supervisado (*k-means* o jerárquico). El *clustering* impone fronteras arbitrarias sobre fenómenos atmosféricos continuos, volviéndose mediocre para agrupar estaciones, ya que cada estación se comporta de manera muy distinta. En su lugar, se adoptó la **Distancia de Mahalanobis** para seleccionar estaciones pivote que capturan la máxima disparidad ambiental de la cuenca.
- 2. Ajuste del Horizonte Predictivo (7 a 14 Días):** Se descartó la proyección a 365 días debido a la acumulación exponencial de error en variables meteorológicas. Un horizonte de 7 a 14 días es técnicamente robusto y funcional para la toma de decisiones preventivas de autoridad.
- 3. Focalización en PM₁₀ como Variable Respuesta:** Se seleccionó PM₁₀ como variable objetivo principal por registrar los picos de contingencia más severos en la metrópoli, conservando la temperatura (TOUT), humedad (RH), velocidad del viento (WSR) y gases precursores (NO₂, SO₂, CO, O₃) como regresores.

Técnicas Estadísticas y Flujo Metodológico

Para dar respuesta al objetivo redefinido, el procesamiento y modelado de datos se estructuró en cinco etapas

metodológicas secuenciales:

1. Agregación Normativa e Imputación Jerárquica

Con el fin de asegurar la representatividad temporal bajo criterios normativos de calidad del aire:

- **Filtro de Representatividad Horaria:** Se calculó el promedio diario únicamente para los días que contaron con al menos 18 lecturas horarias válidas ($\geq 75\%$ de información diaria disponible como lo indica el SIMA).
- **Imputación Secuencial:** Para huecos de información residuales (≤ 3 horas continuas), se aplicó interpolación lineal temporal. Para periodos mayores, se empleó imputación por la media condicional del grupo (Mes-Hora) dentro de la misma estación, garantizando no transferir información entre distintas zonas geográficas.

2. Diagnóstico de Homogeneidad Espacial

Antes de consolidar o agrupar estaciones, se evaluó si la distribución de PM_{10} difiere de manera significativa entre los puntos de monitoreo:

- **Prueba de Levene:** Evaluó la hipótesis nula de homocedasticidad ($\sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$) entre las 15 estaciones del SIMA.
- **ANOVA de Welch:** Dado que se confirmó heterocedasticidad en las mediciones, se utilizó el test de Welch para comparar las medias poblacionales de PM_{10} sin asumir varianzas iguales ni igual tamaño de muestra.

3. Selección por Distancia de Mahalanobis

Para reducir la dimensionalidad de la red de 15 estaciones sin forzar divisiones rígidas mediante *clustering*, se utilizó la Distancia de Mahalanobis. La distancia entre dos estaciones i y j se define como:

$$D_M(\mathbf{u}_i, \mathbf{u}_j) = \sqrt{(\mathbf{u}_i - \mathbf{u}_j)^T S_{\text{pooled}}^{-1} (\mathbf{u}_i - \mathbf{u}_j)}$$

Donde $\mathbf{u}_i$ representa el vector de medias de las variables físico-químicas en la estación i , y S_{pooled} es la matriz de covarianza agrupada calculada sobre toda la red. A través de un algoritmo combinatorio, se seleccionó el trío de estaciones que maximiza la suma de distancias pares acumuladas:

$$\text{Maximizar } \mathcal{D} = D_M(\mathbf{u}_1, \mathbf{u}_2) + D_M(\mathbf{u}_1, \mathbf{u}_3) + D_M(\mathbf{u}_2, \mathbf{u}_3)$$

Este criterio garantiza seleccionar las tres estaciones que capturan la máxima separación conductual y climática de la metrópoli (estaciones pivote).

4. Evaluación de Importancia de Variables con Random Forest

Para identificar qué factores climáticos y precursores inciden en cada zona seleccionada, se entrenó un algoritmo de *Random Forest Regressor* por estación pivote.

- **Variable Respuesta:** Transforma el contaminante a escala logarítmica $\log(1 + PM_{10})$ para estabilizar la varianza ante sesgos positivos y picos atípicos.
- **Métrica de Importancia:** Se extrajo la reducción media de impureza (Gini/MSE) para determinar los regresores dominante por corredor.

5. Estrategia de Modelado Predictivo Temporal

Para responder a la predicción de 7 a 14 días, el problema se estructuró bajo un enfoque autorregresivo multivariado:

- **Ingeniería de Características:** Creación de variables con rezago temporal ($t-1, t-2, t-7$) y promedios móviles de 7 días para capturar la inercia atmosférica.
- **Algoritmo de Estimación:** Ajuste mediante *HistGradientBoostingRegressor* (HGBR), optimizado para series continuas con relaciones no lineales entre meteorología y contaminación.

Resultados del Análisis de esta Etapa

1. Integridad y Perfil Estadístico Post-Procesamiento

Tras aplicar el criterio normativo del SIMA (≥ 18 horas válidas por día) y el esquema de imputación jerárquica (interpolación lineal para ≤ 3 horas y media del grupo Mes-Hora para periodos mayores), el dataset consolidado (2020–2025) alcanzó una cobertura del 100% sin valores nulos ni registros físicamente imposibles. Las variables continuas se resumen cuantitativamente en la Tabla A.1 del Anexo A.

2. Pruebas de Heterocedasticidad y Divergencia Espacial

Para evaluar si las 15 estaciones de monitoreo representan microclimas independientes, se aplicaron pruebas de igualdad de varianza y comparación de medias:

- **Prueba de Levene:** Evaluó la homogeneidad de varianzas en PM_{10} entre las estaciones. El resultado arrojó un estadístico $W = 18.42$ ($p < 0.0001$). Se rechaza

la hipótesis nula de homocedasticidad, confirmando que la dispersión y volatilidad del contaminante difieren drásticamente según la zona geográfica.

- **ANOVA de Welch:** Al confirmarse la heterocedasticidad, se ejecutó la prueba de Welch sobre los promedios de PM_{10} . El resultado arrojó $F_{\text{Welch}} = 142.8$ ($p < 0.0001$), demostrando diferencias altamente significativas en los niveles de contaminación entre estaciones. Esto justifica cuantitativamente evitar el tratamiento uniforme de la metrópoli.

3. Selección Espacial por Distancia de Mahalanobis

Para reducir la dimensionalidad de 15 estaciones sin forzar agrupamientos arbitrarios (*clustering*), se calculó la Distancia Multivariada de Mahalanobis sobre las variables estandarizadas utilizando la matriz de covarianza agrupada S_{pooled} . El algoritmo combinatorio identificó el trío que maximiza la separación ambiental acumulada ($D_M = 15.9513$):

1. **Estación SE3 (Cadereyta):** Captura el impacto directo de emisiones de azufre (SO_2) y refinación.
2. **Estación NO2 (García):** Captura la influencia de pedreteras, polvo seco inorgánico y vientos de barrera montañosa.
3. **Estación NE3 (Pesquería):** Captura la mezcla de tráfico pesado, transporte masivo y parques industriales siderúrgicos.

Las distancias pares obtenidas fueron $D_M(\text{SE3}, \text{NO2}) = 7.37$, $D_M(\text{NO2}, \text{NE3}) = 7.10$ y $D_M(\text{SE3}, \text{NE3}) = 1.48$ (ver matriz extendida en el Anexo B).

4. Importancia de Variables e Insumos Explicativos

El ajuste de *Random Forest Regressor* sobre $\log(1 + PM_{10})$ confirmó patrones explicativos diferenciados por zona (ver Figura A.1 en Anexos).

Es crítico enfatizar que las variables de rezago ($PM_{10,t-1}$, $PM_{10,t-2}$) y el promedio móvil de 7 días ($MA_{7,t-1}$) **no constituyen el modelo de pronóstico final**, sino **columnas de entrada (input features)** derivadas del pasado inmediato. Su inclusión cumple tres funciones esenciales:

- **Saturación Atmosférica:** El MA_7 mide la carga acumulada en la cuenca, permitiendo diferenciar un pico aislado de un solo día de una contingencia ambiental sostenida.
- **Ciclo Semanal:** La ventana de 7 días captura el patrón de actividad industrial y vehicular (días laborales versus fin de semana).

- **Memoria Temporal:** Aporta contexto temporal a algoritmos no secuenciales (*Random Forest*, *Gradient Boosting*), permitiéndoles determinar si la tendencia va en ascenso o en descenso.

Resumen, Conclusiones Parciales y Próximos Pasos

Resumen de Logros

- **Consolidación de datos:** Procesamiento continuo 2020–2025 bajo la regla del 75 % de representatividad e imputación jerárquica.
- **Demstración de heterocedasticidad:** Confirmación estadística mediante Levene y ANOVA de Welch ($p < 0.0001$) de que la ZMM está dividida en microclimas no homogéneos.
- **Selección representativa:** Reducción analítica de 15 a 3 estaciones pivote (SE3, NO2, NE3) mediante Distancia de Mahalanobis ($D_M = 15.9513$).
- **Definición de apoyos temporales:** Estructuración metodológica de variables explicativas de inercia (MA_7 , *lags*).

La sustitución del *clustering* por la selección multivariada mediante la distancia de Mahalanobis demostró ser mejor para capturar la variabilidad de la cuenca atmosférica de Monterrey. Esta estrategia preserva las estaciones extremas representativas sin generar fronteras artificiales, proporcionando la base óptima para entrenar modelos predictivos enfocados en alertas tempranas a corto plazo (7 a 14 días).

Próximos Pasos y Ruta de Trabajo

1. **Construcción de la Matriz de Entrenado:** Ensamblar para las 3 estaciones pivote los conjuntos de datos con lags ($t - 1$ a $t - 7$), promedios móviles (MA_7 , MA_{14}) y métricas meteorológicas exógenas.
2. **Entrenamiento y Validación:** Entrenar modelos de *HistGradientBoostingRegressor* (HGBR) utilizando una partición temporal (Entrenamiento: 2020–2024; Validación/Prueba: 2025).
3. **Evaluación de Desempeño:** Evaluar la precisión mediante MAE , $RMSE$ y R^2 en las ventanas predictivas de 7 y 14 días.

Preguntas Emergentes de Investigación

- ¿El error de predicción a 14 días aumenta de forma lineal o exponencial en comparación con la ventana de 7 días?
 - ¿Requiere la estación Poniente (N02) una ponderación superior de la velocidad del viento (*WSR*) durante los meses invernales debido a las ráfagas locales de polvo inorgánico?
-

Anexos

Anexo A: Descriptivos y Panel Visual Multivariado

Tabla A.1: Estadísticos Descriptivos de las Variables Continuas (2020–2025)

Variable	Descripción	Unidad	Media	Mediana	Desv. Est.	IQR	Mín	Máx
PM_{10}	Partículas en suspensión < 10 μm	$\mu g/m^3$	62.45	54.10	38.20	42.15	2.10	380.00
$PM_{2.5}$	Partículas finas < 2.5 μm	$\mu g/m^3$	24.18	21.00	14.30	16.50	0.50	195.00
O_3	Ozono troposférico	ppb	28.35	25.20	18.10	22.40	0.00	145.00
NO_2	Dióxido de nitrógeno	ppb	15.80	13.90	9.40	11.20	0.00	85.00
SO_2	Dióxido de azufre	ppb	7.62	4.80	8.15	6.90	0.00	92.00
$TOUT$	Temperatura ambiente	°C	22.40	23.10	6.85	9.50	-2.50	43.80
RH	Humedad relativa	%	58.20	60.10	19.40	28.30	8.00	99.00
WSR	Velocidad del viento	km/h	8.45	7.20	4.60	5.80	0.10	42.00

La Distancia Multivariada de Mahalanobis entre dos vectores de medias $\mathbf{u}_i$ y $\mathbf{u}_j$ pondera la separación ajustando por la covarianza inter-variable de la cuenca atmosférica mediante la siguiente expresión:

$$D_M(\mathbf{u}_i, \mathbf{u}_j) = \sqrt{(\mathbf{u}_i - \mathbf{u}_j)^T S_{\text{pooled}}^{-1} (\mathbf{u}_i - \mathbf{u}_j)}$$

Donde la matriz de covarianza agrupada S_{pooled} para k estaciones con n_s observaciones y matrices de covarianza individuales S_s se define formalmente como:

$$S_{\text{pooled}} = \frac{1}{\sum_{s=1}^k (n_s - 1)} \sum_{s=1}^k (n_s - 1) S_s$$

Table 1: Matriz de Distancias de Mahalanobis entre Estaciones Pivote (D_M)

Estación Pivote	SE3 (Oriente)	NO2 (Poniente)	NE3 (Norte)
SE3 (Cadereyta / Juárez)	0.00	7.37	1.48
NO2 (García / San Bernabé)	7.37	0.00	7.10
NE3 (Pesquería / Apodaca)	1.48	7.10	0.00




Figure 1: Figura A.1: Panel multivariado de comportamiento espacial, meteorológico e importancia de insumos en estaciones pivote.