

PARTE 2. COMPRENSIÓN Y PREPARACIÓN DE LOS DATOS

Equipo 6

Importación y estructuración de los datos

Antes de iniciar con la exploración de los datos, es necesario importar y estructurar los datos de los archivos Excel que contienen la información de cada año, ya que se encontró que los archivos contienen varias hojas y que la cantidad de valores nulos varía entre los años. Por lo tanto, se concatenarán las hojas de cada año y se agregará una columna indicativa a la estación de la observación, después se realizará un análisis comparativo de los valores nulos por año para determinar cuál año tiene la menor cantidad de datos faltantes y, por ende, será el año seleccionado para la exploración de los datos.

```
import pandas as pd
import numpy as np

# Lista para guardar el resumen de calidad de cada año
resultados = []

# Ciclo para procesar los archivos Excel del 2020 al 2025
for anio in range(2020, 2026):
    nombre_excel = f'BD {anio}.xlsx'
    nombre_csv_salida = f'BD_{anio}_Completo.csv'

    try:
        # 1. Leer todas las pestañas del Excel
        diccionario_hojas = pd.read_excel(nombre_excel, sheet_name=None)
        lista_tablas = []

        # 2. Recorrer cada pestaña, agregar la estación y guardarla en la lista
        for nombre_pestana, df_temporal in diccionario_hojas.items():
            df_temporal['Estacion'] = nombre_pestana
            lista_tablas.append(df_temporal)
```

```

# 3. Unir todas las tablas en un solo DataFrame
df_anio_completo = pd.concat(lista_tablas, ignore_index=True)

# 4. Guardar la nueva base de datos combinada
df_anio_completo.to_csv(nombre_csv_salida, index=False)

# 5. Calcular los valores nulos para la comparativa
total_filas = len(df_anio_completo)
total_nulos = df_anio_completo.isna().sum().sum()

resultados.append({
    'Año': anio,
    'Total Filas': total_filas,
    'Valores Nulos': total_nulos,
    'Archivo Generado': nombre_csv_salida
})
print(f"¡Éxito! Archivo guardado: {nombre_csv_salida}")

except FileNotFoundError:
    print(f"Aviso: El archivo {nombre_excel} no se encontró en la carpeta.")

# Mostrar la tabla comparativa ordenada por cantidad de nulos
if resultados:
    df_comparativo = pd.DataFrame(resultados)
    print("\n--- Comparativa de Calidad de Datos por Año ---")
    print(df_comparativo.sort_values(by='Valores Nulos'))
else:
    print("No se procesaron archivos. Verifica los nombres y la ubicación.")

```

```

¡Éxito! Archivo guardado: BD_2020_Completo.csv
¡Éxito! Archivo guardado: BD_2021_Completo.csv
¡Éxito! Archivo guardado: BD_2022_Completo.csv
¡Éxito! Archivo guardado: BD_2023_Completo.csv
¡Éxito! Archivo guardado: BD_2024_Completo.csv
¡Éxito! Archivo guardado: BD_2025_Completo.csv

```

```

--- Comparativa de Calidad de Datos por Año ---

```

	Año	Total Filas	Valores Nulos	Archivo Generado
2	2022	123383	84056	BD_2022_Completo.csv
3	2023	131370	103402	BD_2023_Completo.csv
4	2024	131741	139587	BD_2024_Completo.csv

1	2021	122629	197665	BD_2021_Completo.csv
5	2025	131378	212002	BD_2025_Completo.csv
0	2020	114102	552931	BD_2020_Completo.csv

Como podemos observar, el año 2022 es el que tiene la menor cantidad de valores nulos, por lo que se seleccionará este año para la exploración de los datos.

Medidas de tendencias centrales

```
df = pd.read_csv('BD_2022_Completo.csv', sep = ';')

def medidas_centrales(df: pd.DataFrame):
    display('Media',df.mean(numeric_only=True, skipna=True),
            'Mediana',df.median(numeric_only=True,skipna= True))
    max = df.max(numeric_only=True, skipna=True)
    min = df.min(numeric_only=True, skipna=True)
    display('Rango medio',(max-min)/2)

medidas_centrales(df)
```

'Media'

Series([], dtype: float64)

'Mediana'

Series([], dtype: float64)

'Rango medio'

Series([], dtype: float64)

La variable RAINF es cero en su totalidad, más adelante, haría falta el visualizar si es que esto mismo concuerda con los demás años para saber si esta variable tiene significancia alguna.

Por otro lado, la variable que menos parecen moverse y son bajos, aparte de la RAINF, es el CO, teniendo muy poca dispersión de estas medidas. Esto mismo podría significar un comportamiento normal. Esto es cosa distinta de los compuestos con nitrógeno, pues parecen

estar más despegados. Eso podría significar que su comportamiento es más volátil que el de CO.

Por último, la variable PRS, parece tener el mayor desbalance en diferencia de rango medio, y media y mediana. Al igual que la cantidad presente media de este compuesto a lo largo del 2022 es mucho más alta que las demás.

NOTA: investigar este compuesto o la razón de esta variable

Matriz de covarianzas

```
cols = df.columns[1:df.shape[1]]
df = df[cols]
df.to_csv('BD 2022.csv', sep = ';')
means = np.mean(df, axis = 0)
means
```

Series([], dtype: float64)

```
df_center = df-means
df_center.head
np.transpose(df_center) @ df_center/df_center.shape[0]
```